# Einführung in R & RStudio – Tag 1

**Grundlagen, Objekte & erste Daten**

## Ankommen & Setup

Willkommen zum Workshop „Einführung in R & RStudio“  An Tag 1 legen wir die Grundlagen, die wir am zweiten Tag weiter vertiefen.

**Ziele für heute** - RStudio Oberfläche kennenlernen - verstehen, wie R „denkt“ - erste eigene Objekte und Daten erzeugen

---

## Was ist R und Rstudio?

**R** ist eine freie Programmiersprache, mit der man *Daten analysieren, auswerten und grafisch* darstellen kann.

**Du kannst mit R zum Beispiel:**

- Tabellen mit vielen Zahlen auswerten
- Mittelwerte, Häufigkeiten oder Korrelationen berechnen
- Diagramme und Grafiken erstellen
- Daten aufbereiten, filtern und umformen

**R** wird häufig in den Sozialwissenschaften, der Psychologie, der Medizin und vielen anderen Forschungsbereichen genutzt, unabhänging ob ***quantitativ oder qualitativ*** gearbeitet wird. Der große Vorteil von **R** ist, dass alle Analyseschritte transparent, nachvollziehbar und reproduzierbar sind – man kann also genau sehen, wie ein Ergebnis entstanden ist.

**RStudio** ist ***keine eigene Programmiersprache***, sondern ein Programm, das dir die Arbeit mit R erleichtert. Man kann sich **RStudio** wie einen Schreibtisch für *R* vorstellen.

**RStudio hilft dir dabei:**

- Codes übersichtlich zu schreiben
- Befehle auszuführen und Ergebnisse zu sehen
- deine Daten, Objekte und Grafiken im Blick zu behalten
- Dateien und Projekte organisiert zu verwalten

Ohne ***RStudio*** müsstest du **R** über ein sehr einfaches Fenster bedienen. Mit RStudio bekommst du eine strukturierte Oberfläche, die besonders für Einsteiger:innen viel angenehmer ist.

---

## R GUI - erste Ansicht

Schauen wir uns zunächst die **R Oberfläche** ***(ohne RStudio)*** an.

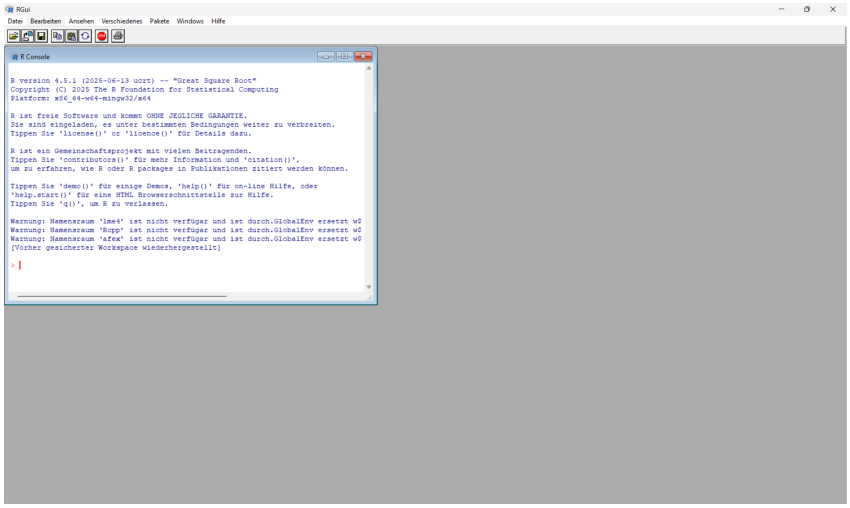


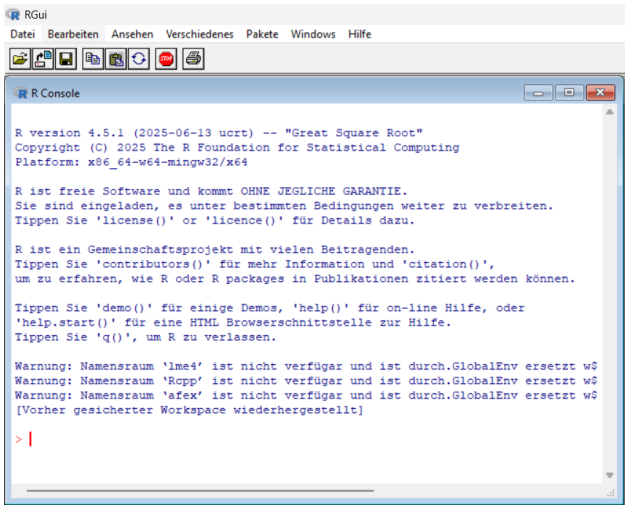

**Was sehen wir hier?**

- ***Linkes Bild***
  - Die "normale" **R Oberfläche**
    - Sie besteht zunächst nur aus einer ***R Console***
- ***Rechtes Bild***
  - Die **R Console**
    - Hier werden Befehle direkt eingegeben
    - Ergebnisse erscheinen sofort darunter

> **Note**
>
> **Hinweis**
> Alles, was du in die Konsole eingibst, wird sofort von R ausgeführt.
> Das Ergebnis siehst du direkt unter der eingegebenen Zeile.
> ***Beispiel***
>
> - gib `13`ein
> - gib `a` ein
> - gib `13+15`
>
> **Caution**
>
> **ABER**
>
> Wir brauchen ***R GUI*** nicht, sondern nutzen **RStudio!**

## RStudio - Unser Cockpit

Schauen wir uns nun die Oberfläche von **RStudio** an. Startet einfach **RStudio** ***(nicht R GUI!)***. Ihr müsst nun das folgende Bild sehen:

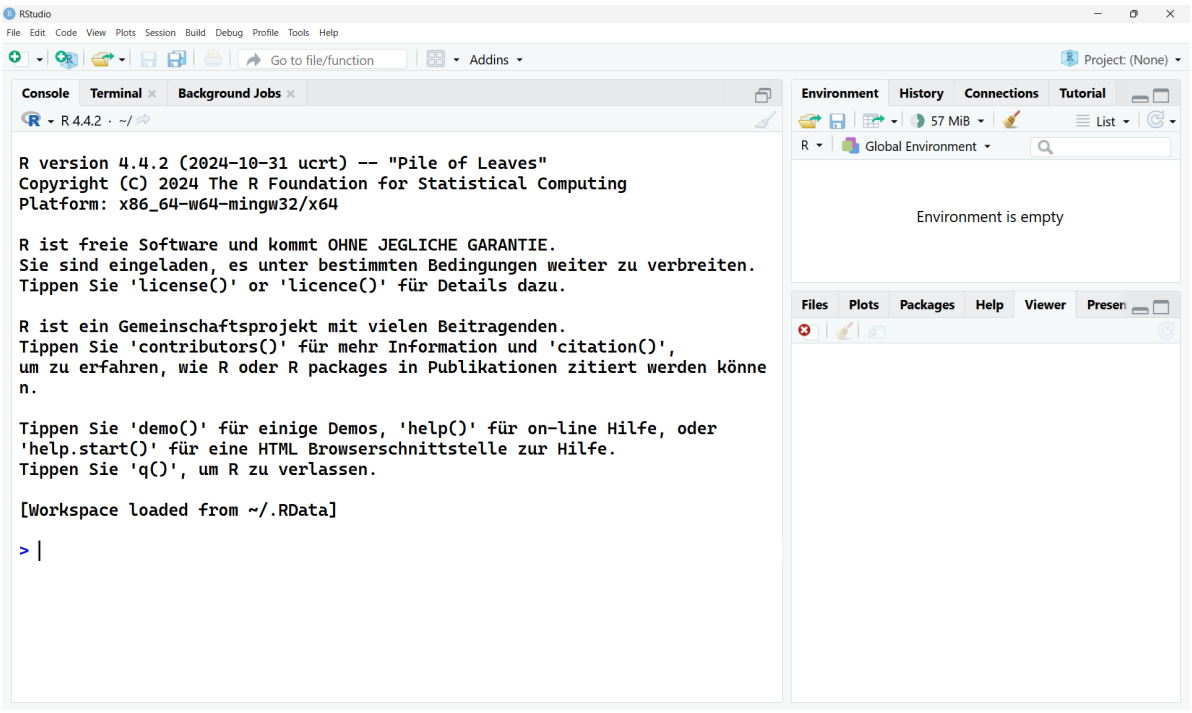


**Wir schauen uns nun die Menü-Leiste von RStudio an:**

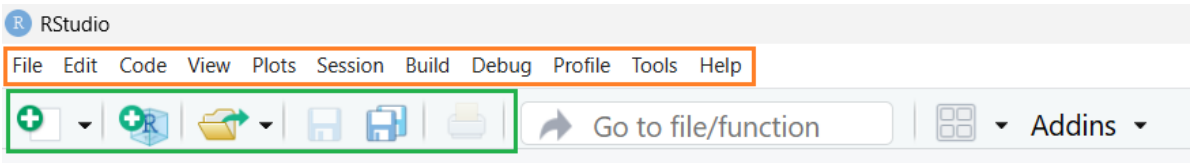


Orange – die Menü-Leiste

In der Menü-Leiste findest du alle wichtigen Funktionen von RStudio übersichtlich nach Themen sortiert. Hier kannst du zum Beispiel Dateien öffnen und speichern, Einstellungen ändern, Codes ausführen oder Hilfe aufrufen. *Das Aussehen deines RStudios kannst du auch hier anpassen!*

Grün – die Schnellzugriff-Leiste

Die Schnellzugriff-Leiste enthält häufig genutzte Funktionen als Symbole. Damit kannst du z. B. schnell neue Dateien erstellen, Skripte speichern oder Codes ausführen, ohne durch Menüs zu klicken.

## Die vier Bereiche von RStudio

RStudio ist in **vier Arbeitsbereiche** (Panes/Paneele) aufgeteilt. Jeder Bereich hat eine eigene Aufgabe. Aber jetzt gerade siehst du nur drei Bereiche. Ich zeige dir jetzt erstmal, wie du die

vier Bereiche bekommst!

> **Note**
>
> Hierfür gehst du zunächst in die **Schnellzugriffs-Leiste** und klickst auf das Symbol ganz links, das **weiße Blatt** mit dem **Plus**.
>
> 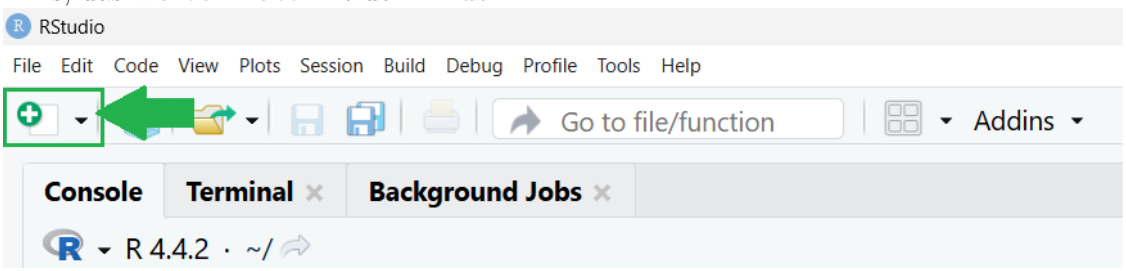
> 
>
> Anschließend öffnet sich ein **Drop-Down** und du kannst jetzt schon sehen, was du alles mit ***RStudio*** machen kannst.

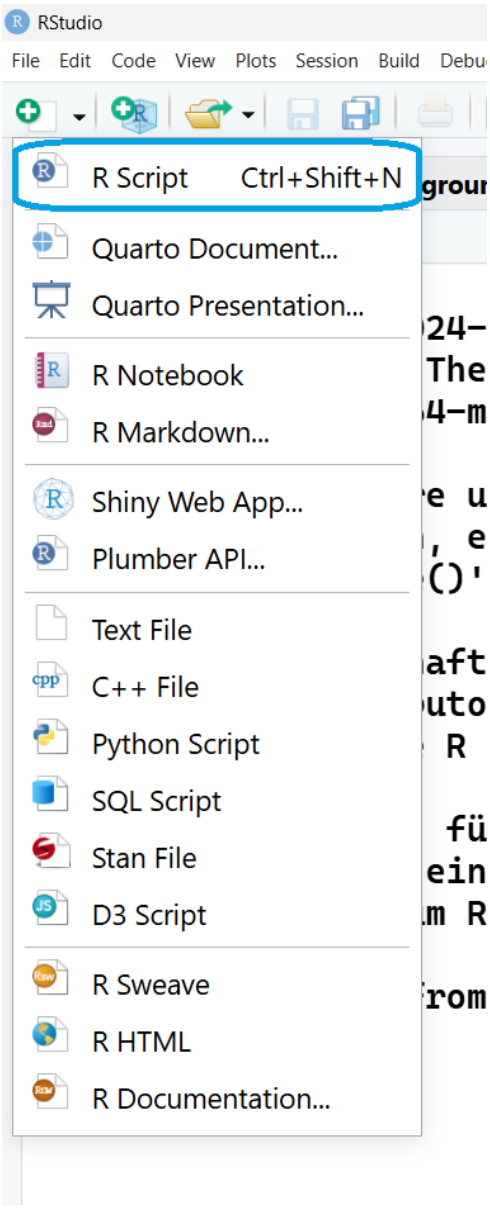


Wir wollen aber ein neues `**R Script erstellen**`, daher klicken wir auch da drauf!

> **Tip**
>
> Übrigens diese Workshopseite wurde komplett mit RStudio und Quarto Markdowns erstellt.

Jetzt sollte dein RStudio so aussehen:

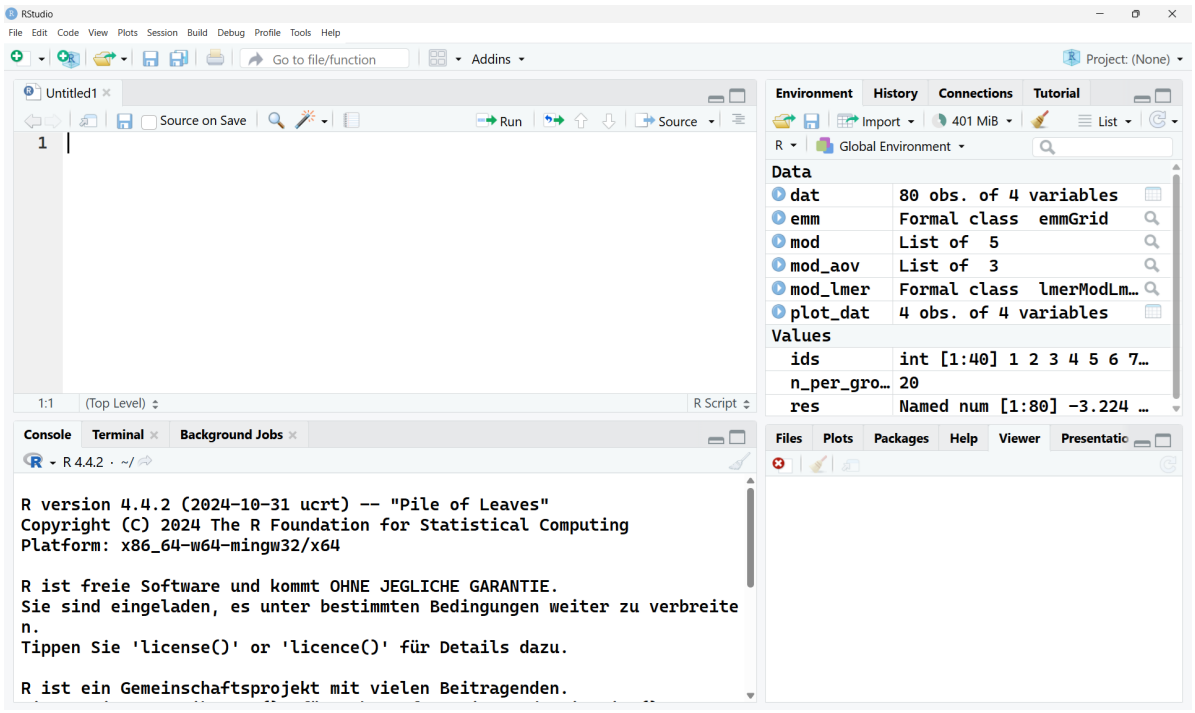
RStudio
File Edit Code View Plots Session Build Debug Profile Tools Help
Go to file/function
Addins
Project: (None)
Untitled1
Source on Save
Run
Source
1
1:1
(Top Level)
R Script
Environment
History
Connections
Tutorial
Import
401 MiB
List
R
Global Environment
Data
dat
80 obs. of 4 variables
emm
Formal class emmGrid
mod
List of 5
mod_aov
List of 3
mod_lmer
Formal class lmerModLm…
plot_dat
4 obs. of 4 variables
Values
ids
int [1:40] 1 2 3 4 5 6 7…
n_per_gro…
20
res
Named num [1:80] -3.224 …
Console
Terminal
Background Jobs
R 4.4.2 · ~/
R version 4.4.2 (2024-10-31 ucrt) -- "Pile of Leaves"
Copyright (C) 2024 The R Foundation for Statistical Computing
Platform: x86_64-w64-mingw32/x64
R ist freie Software und kommt OHNE JEGLICHE GARANTIE.
Sie sind eingeladen, es unter bestimmten Bedingungen weiter zu verbreite
n.
Tippen Sie 'license()' or 'licence()' für Details dazu.
R ist ein Gemeinschaftsprojekt mit vielen Beitragenden.
Files
Plots
Packages
Help
Viewer
Presentatio

### Skript-Editor (oben links)

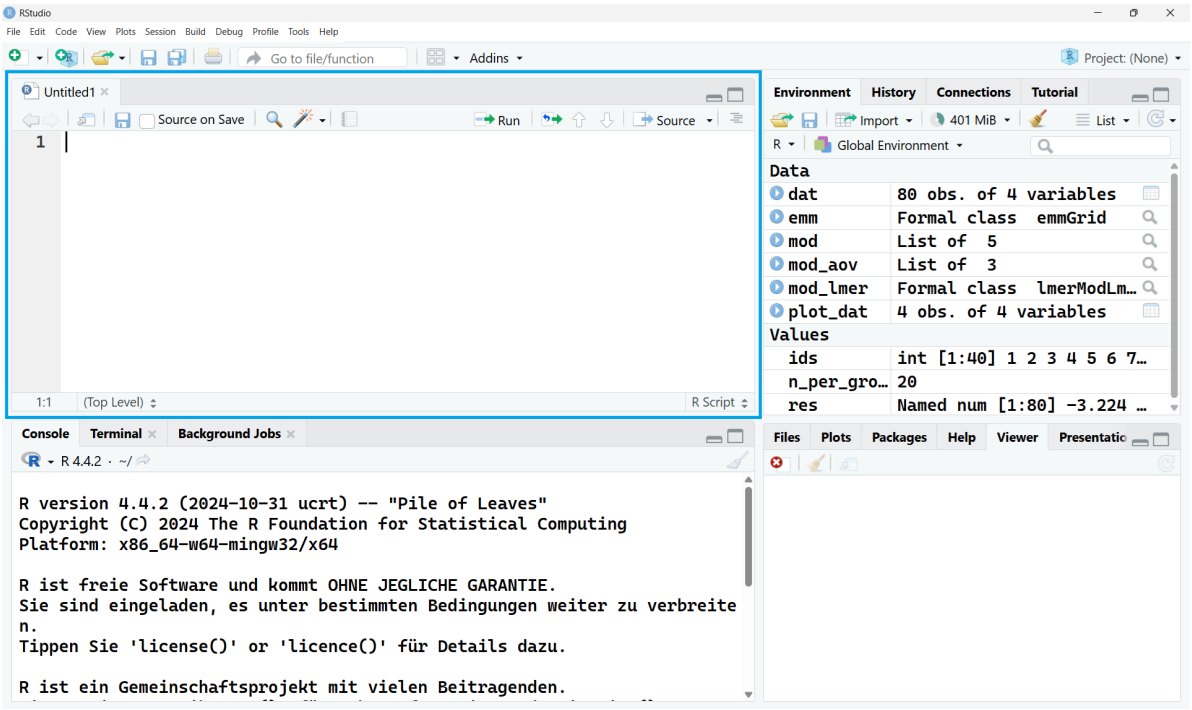


Hier schreibst du deinen **Code** in Skripten.

- Codes werden **nicht sofort** ausgeführt
- du kannst ihn speichern, verändern und wiederverwenden
- ideal für sauberes, nachvollziehbares Arbeiten

> **Note**
>
> **Merke:**
> Alles Wichtige gehört ins **Skript**, nicht nur in die Konsole.

### Konsole (unten links)

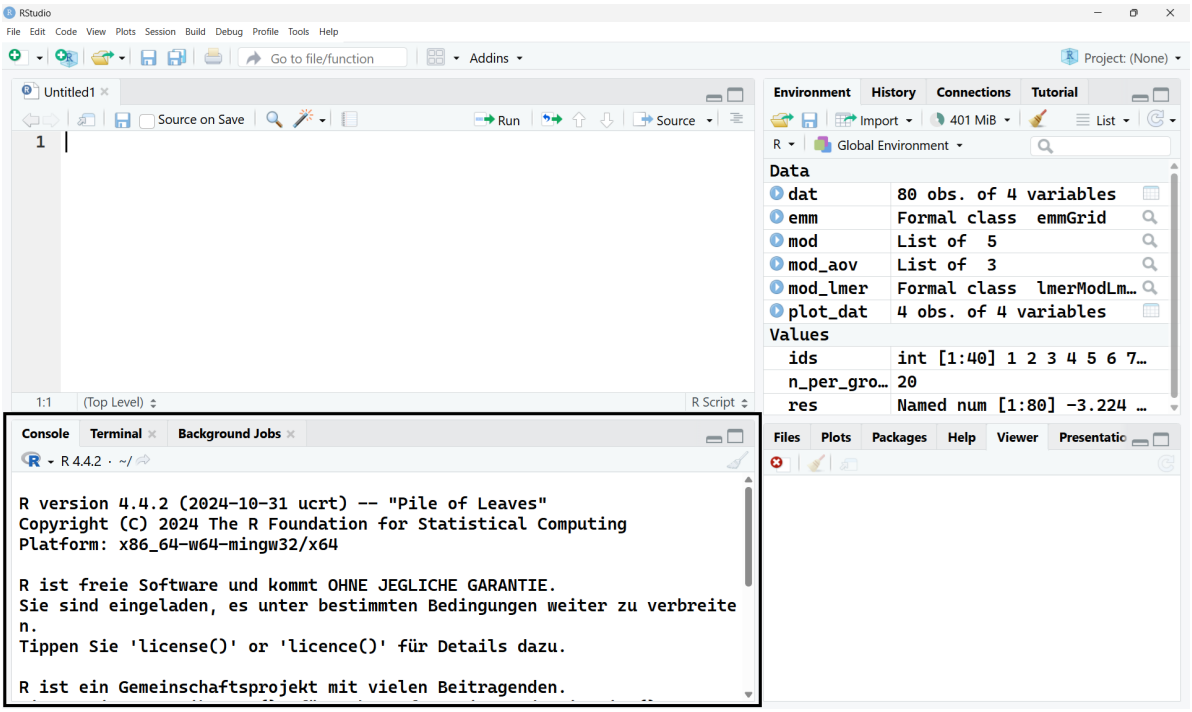


Die ***Konsole*** kennen wir im Grunde schon. Wie du vielleicht schon erkannt hast, ist es die selbe Konsole wie bei **R GUI**.

- hier führt R Befehle aus
- Ergebnisse erscheinen direkt darunter
- gut zum Ausprobieren und Testen

Code aus dem Skript kann mit **Run** oder **Strg + Enter** ausgeführt werden.

### Environment & History (oben rechts)

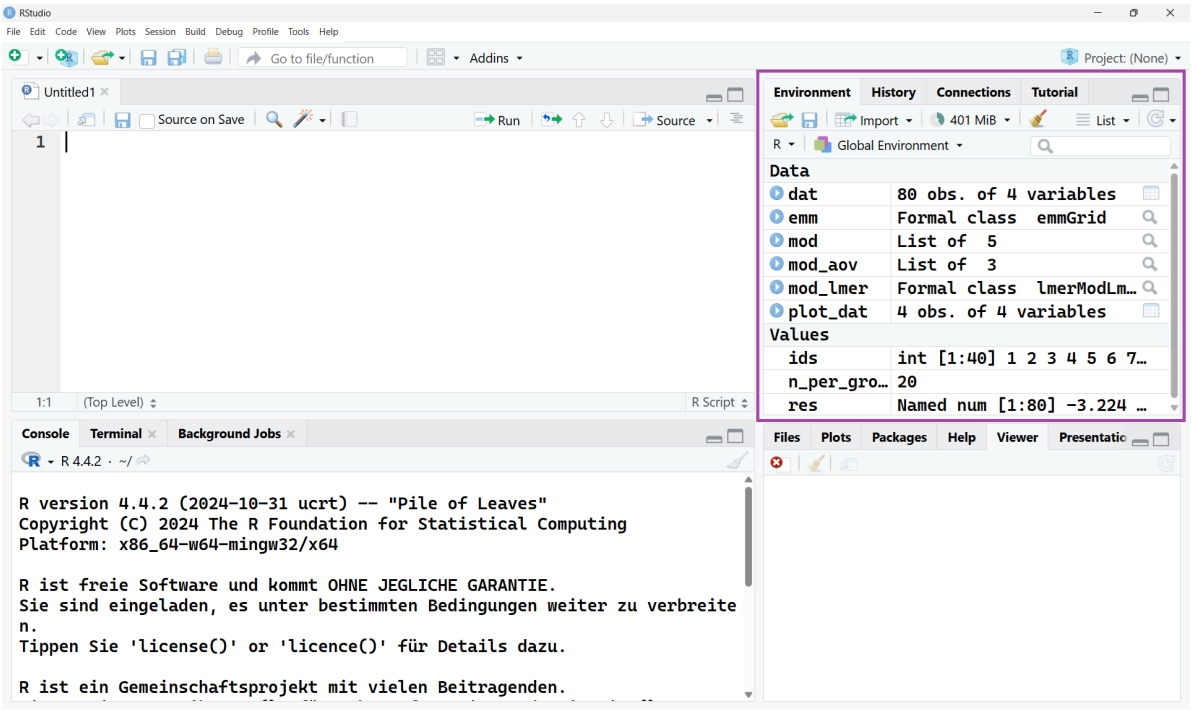


Im **Environment** siehst du:

- alle Objekte, die du erstellt hast
- z. B. Variablen, Daten, Ergebnisse

In der **History** findest du:

- frühere Befehle, die du eingegeben hast

So behältst du den Überblick, was gerade „im Speicher“ liegt.

### Files, Plots, Packages, Help (unten rechts)

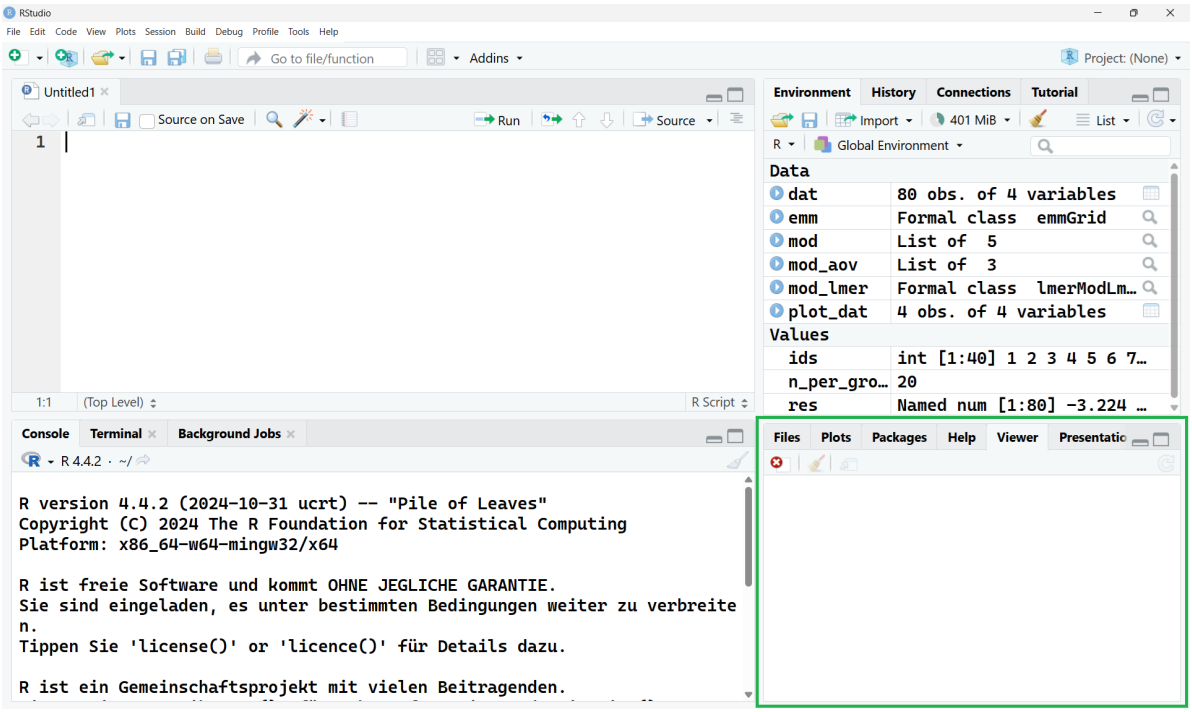


Dieser Bereich zeigt dir:

- **Files**: deine Dateien und Ordner
- **Plots**: Grafiken, die du erzeugst
- **Packages**: installierte Erweiterungen
- **Help**: Hilfeseiten zu Funktionen

Hier findest du fast alles, was R zusätzlich ausgibt und wo es gespeichert ist.

> **!** Important
>
> Im nächsten Abschnitt legen wir unser erstes **Projekt** an!

---

## Projekt anlegen

Ein Projekt hilft dir, **strukturiert und reproduzierbar** zu arbeiten.

- alle Dateien (Skripte, Daten, Grafiken) liegen an einem festen Ort

- R weiß immer, **wo es die Dateien findet** (keine kaputten Pfade)
- du kannst deine Arbeit jederzeit schließen und **genau dort weitermachen**
- besonders wichtig für größere Analysen und gemeinsames Arbeiten

**Merke:**
Ein neues Projekt = ein neuer, sauberer Arbeitskontext.

> ⚠ Warning
>
> **Typischer Anfängerfehler**
> Viele arbeiten **ohne Projekt** und laden Dateien „irgendwoher“.
> Das führt oft zu:
>
> - Fehlermeldungen wie *„file not found“*
> - nicht reproduzierbaren Analysen
> - Verwirrung, wenn man die Sitzung neu startet
>
> **Gewöhne dir an:**
> Für **jedes Projekt** ein eigenes RStudio-Projekt anzulegen.

#### Projekt anlegen – Schritt für Schritt

1. Klicke oben auf **File → New Project...** in der Menü-Leiste
2. Wähle **New Directory**
3. Wähle **New Project**
4. Vergib einen **sinnvollen Namen** (z. B. `r_workshop_tag1`)
5. Wähle einen Speicherort auf deinem Rechner
6. Klicke auf **Create Project**

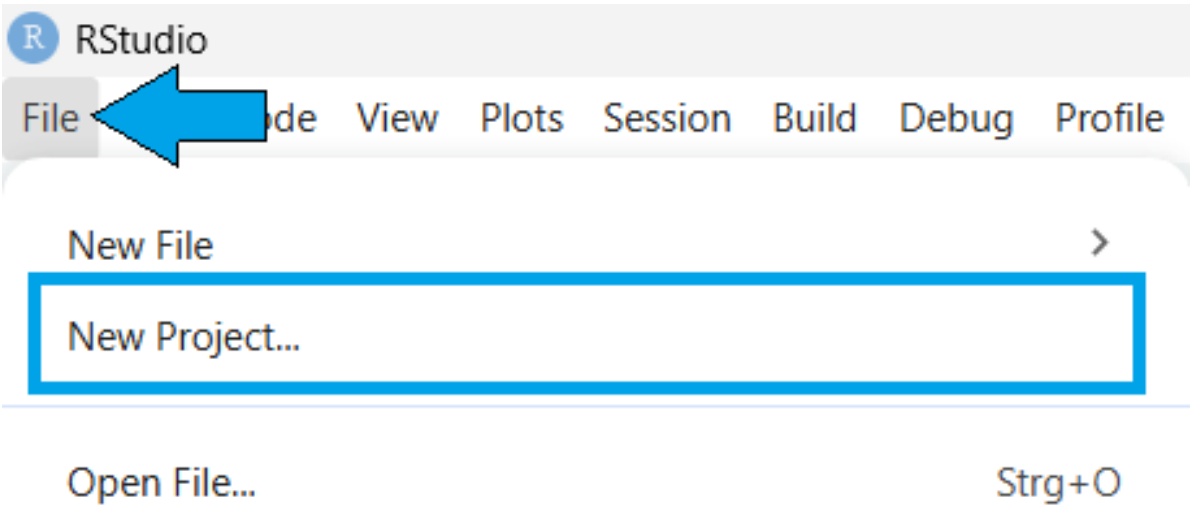


**Schritt 1:**
*File* → *New Project...*

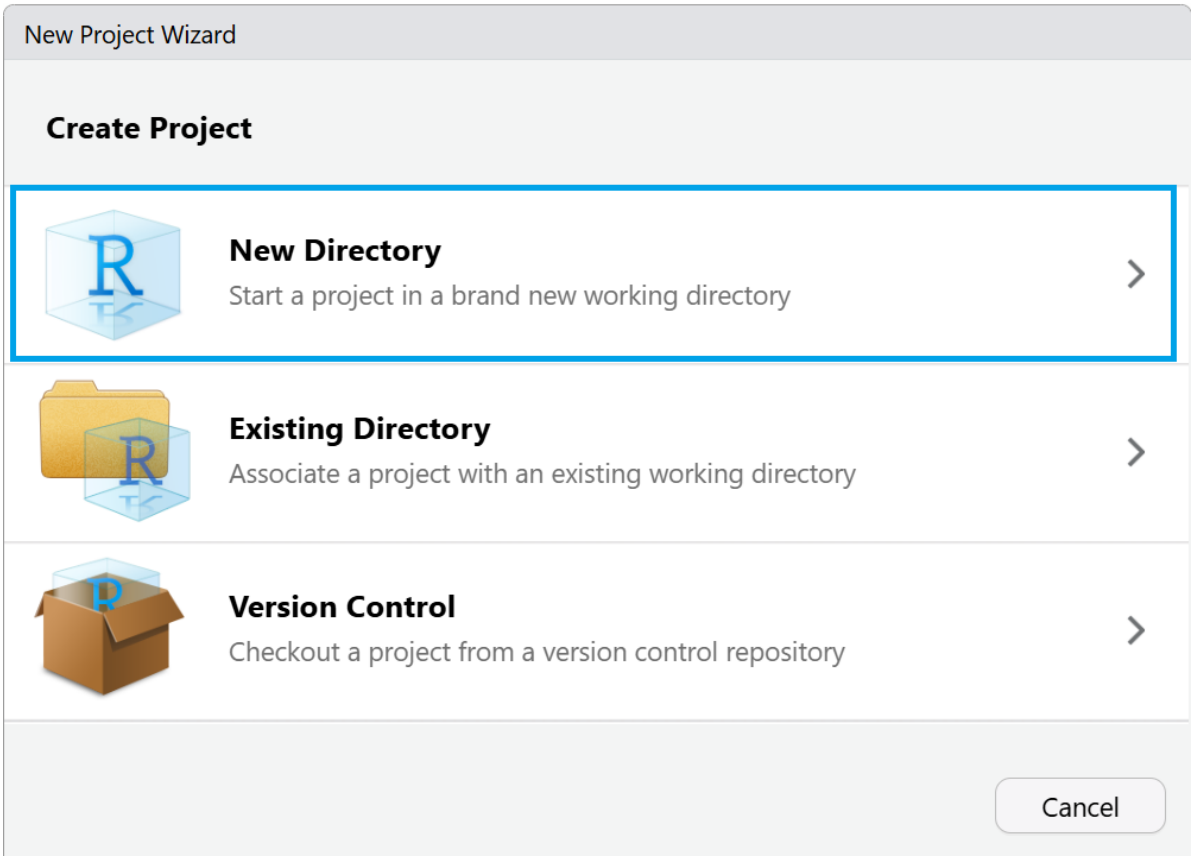


**Schritt 2:**

*New Directory*

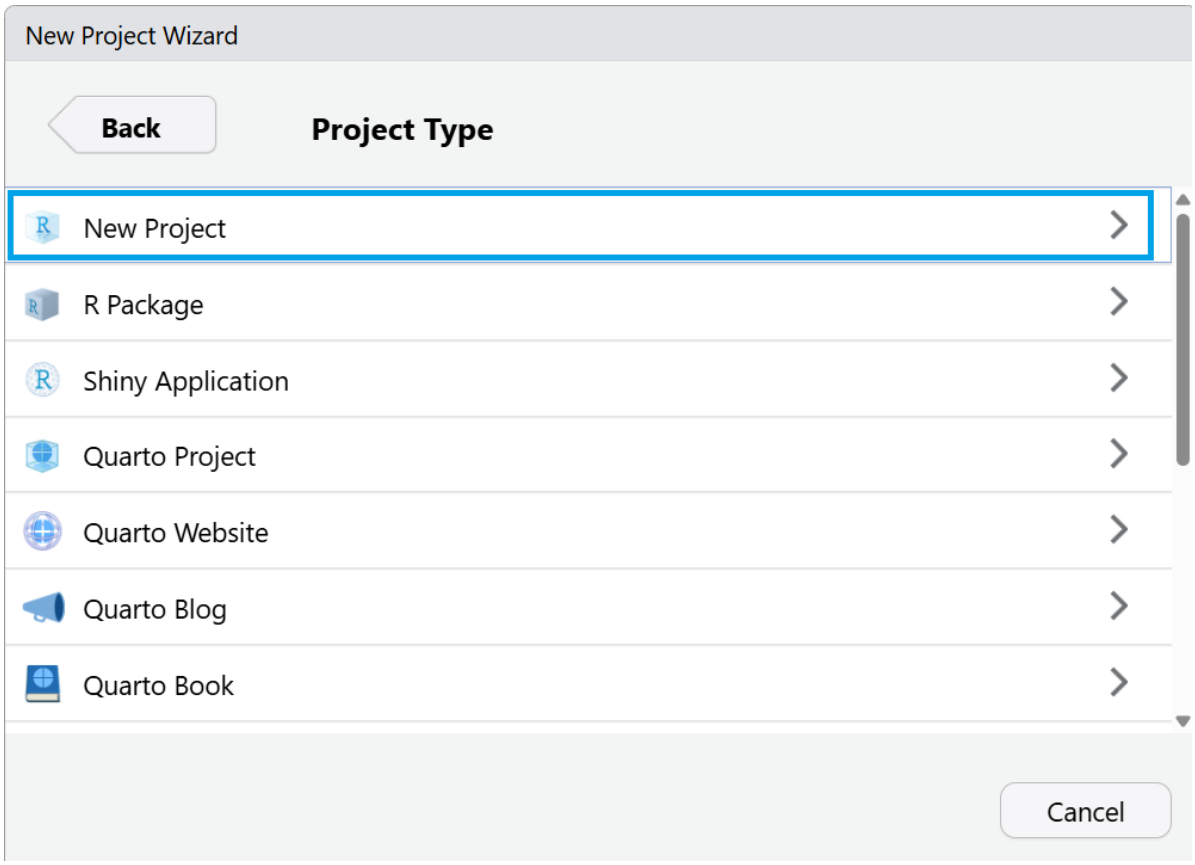


**Schritt 3:**
*New Project*

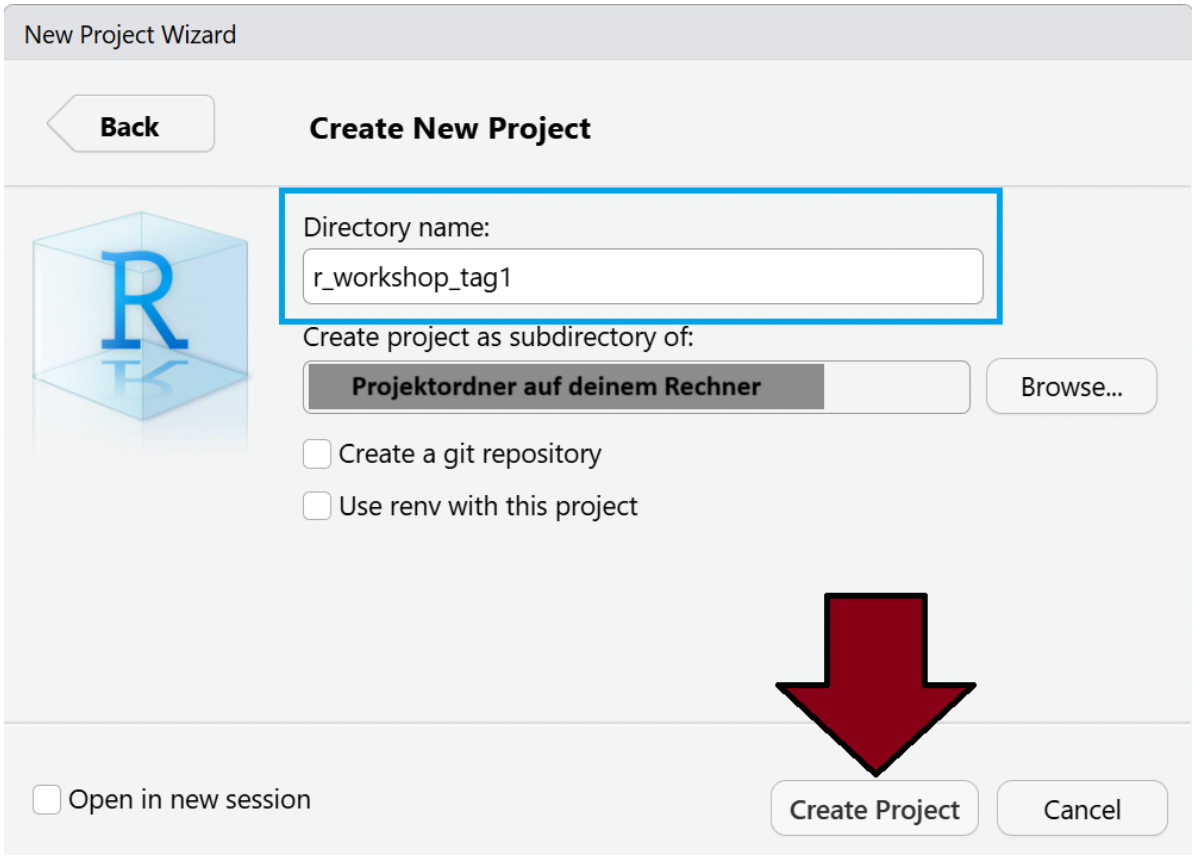


**Schritt 4 bis 6:**
*Name vergeben, Speicherort wählen & Create Project*

> Tip
>
> **Tipp:**
> Der Projektname sollte **keine Leerzeichen** enthalten
> (z. B. `r_workshop_tag1` statt `R Workshop Tag 1`)

**RStudio startet nun neu – du arbeitest jetzt *innerhalb deines Projekts.***

---

## R Script

Nachdem wir nun ein Projekt angelegt haben, beginnen wir mit dem eigentlichen Arbeiten in einem **R Script**.

Ein Script ist eine Textdatei, in der du deine Befehle sammelst und speicherst. So kannst du: - deine Arbeit nachvollziehen - Code später wiederverwenden - Analysen Schritt für Schritt dokumentieren

RStudio bietet viele Möglichkeiten, mit R zu arbeiten. Wir starten bewusst **sehr einfach**, um ein Gefühl dafür zu bekommen, wie R reagiert.

**Erinnerung**

Mit **Strg + Enter** wird der Befehl **in der Zeile ausgeführt, in der dein Cursor steht** –
du musst den Code **nicht markieren** und **nicht auf „Run“ klicken**.

### RStudio als Taschenrechner

Zum Einstieg kannst du RStudio wie einen **Taschenrechner** benutzen.

Du gibst einen Befehl ein – R rechnet – und gibt das Ergebnis zurück. So lernst du schnell:

- wie Befehle aufgebaut sind
- wie R mit Zahlen umgeht
- dass R immer auf **Eingaben reagiert**

```
2 + 2
```

```
[1] 4
```

```
10 / 3
```

```
[1] 3.333333
```

```
sqrt(49)
```

```
[1] 7
```

Warum ins Skript schreiben?

Befehle, die du **nur in der Konsole** eingibst, sind schnell wieder weg –
du musst später mühsam hochscrollen, um sie zu finden.
Schreibst du deine Rechnungen **in ein R Script**, bleiben sie erhalten:

- du kannst sie jederzeit wieder ausführen
- du behältst den Überblick
- deine Arbeit ist nachvollziehbar und reproduzierbar

**Übung 1** – R als Taschenrechner

1. Berechne zuerst den Ausdruck
   `((8 + 4)^2 - 10) / 2`.
2. Berechne anschließend
   `sqrt(196) + 3^3`.
3. Führe **alle Rechnungen**
   - einmal direkt in der **Konsole**
   - und einmal aus einem **Skript**

Beobachte, was gleich ist und was sich unterscheidet.

**Lösung Übung 1**

```
#Aufgabe 1
((8 + 4)^2 - 10) / 2
```

```
[1] 67
```

```
#Aufgabe 2
sqrt(196) + 3^3
```

```
[1] 41
```

## Grundprinzipien von R

R arbeitet objektorientiert: Alles, was du erzeugst, kann ein Objekt sein und bekommt einen Namen.

```
x <- 5
y <- c(23, 12, 11, 9, 13)
```

**Hinweis**

- `<-` ist der **Zuweisungspfeil**: Er weist den Wert rechts dem Namen links zu.
- `c()` steht für **combine**: Damit fasst R mehrere Werte zu einem **Vektor** zusammen.
- `y` ist der **Name des Objekts**. Das Objekt selbst ist ein **Vektor**, der mehrere Zahlen enthält.

### Funktionen verwenden

Funktionen sind **vordefinierte Befehle**, mit denen R etwas für uns erledigt.
Sie nehmen einen oder mehrere **Eingabewerte** entgegen, führen damit eine bestimmte Operation aus und geben ein **Ergebnis** zurück.

Man kann sich Funktionen wie **Werkzeuge** vorstellen:
Je nach Aufgabe benutzen wir ein anderes Werkzeug.

In R werden Funktionen immer mit **runden Klammern `()`** aufgerufen.

Im Folgenden verwenden wir einige **grundlegende Funktionen**, die R bereits mitbringt:

```
sum(y)
```

```
[1] 68
```

```
mean(y)
```

```
[1] 13.6
```

```
sd(y)
```

```
[1] 5.458938
```

```
median(y)
```

```
[1] 12
```

```r
mad(y)
```

```
[1] 1.4826
```

```r
min(y)
```

```
[1] 9
```

```r
max(y)
```

```
[1] 23
```

```r
range(y)
```

```
[1]  9 23
```

```r
length(y)
```

```
[1] 5
```

**Was machen diese Funktionen?**

- `sum()` – berechnet die **Summe** aller Werte
- `mean()` – berechnet den **Mittelwert**
- `sd()` – berechnet die **Standardabweichung**
- `median()` – gibt den **Median** zurück
- `mad()` – berechnet die **mittlere absolute Abweichung**
- `range()` – gibt **kleinsten und größten Wert** aus
- `min()` – kleinster Wert
- `max()` – größter Wert

- `length()` – Anzahl der Werte

Es gibt eine Vielzahl **Base R Funktionen**, ihr könnt sie gerne erkundigen!

Funktionen können nicht nur einzeln verwendet werden, sondern auch **miteinander kombiniert** werden.
Das Ergebnis einer Funktion kann dabei **direkt als Eingabe** für eine andere Funktion dienen.

Zum Beispiel können wir den Mittelwert berechnen und anschließend daraus die Wurzel ziehen, oder wir kombinieren mehrere Funktionen, um neue Kennwerte zu berechnen.

```
sqrt(mean(y))
```

```
[1] 3.687818
```

```
max(y) - min(y)
```

```
[1] 14
```

In der nächsten Übung nutzen wir diese Grundfunktionen,
um eigene Kennwerte zu berechnen und die Ergebnisse **als Objekte zu speichern**.

**Übung 2** – Funktionen

Nutze den Vektor `y` und berechne folgende Kennwerte:

1. Den **Standardfehler des Mittelwerts**
2. Die **Varianz**
3. Die **z-standardisierten Werte** (z-Werte)
4. Das **95%-Konfidenzintervall** (KI) für den Mittelwert

Speichere alle Ergebnisse als eigene Objekte, z. B.: `se_y`, `var_y`, `z_y`, `ci_y`.

**Tipp: Formeln für die Berechnung**

Du darfst dir für die Berechnung **Hilfsobjekte** anlegen.

---

**Standardfehler des Mittelwerts**

$$SE = \frac{sd(x)}{\sqrt{n}}$$

- $sd$ = Standardabweichung
- $n$ = Anzahl der Werte

---

**Varianz (Stichprobe)**

$$\text{Var} = \frac{1}{n-1} \sum (x - \bar{x})^2$$

- $\bar{x}$ = Mittelwert der Daten
- $\sum$ = Summe über alle Beobachtungen

---

**z-Standardisierung**

$$z = \frac{x - \bar{x}}{sd(x)}$$

---

**95%-Konfidenzintervall des Mittelwerts**

$$\bar{x} \pm t_{0.975,\, n-1} \cdot SE$$

- $t_{0.975,\, n-1}$ = kritischer t-Wert für ein **95 %-Konfidenzintervall**. In R `qt(0.975, df = n - 1)`
- $\pm$ = untere und obere Grenze des Intervalls

**Lösung – Übung 2**

```r
# Hilfsobjekte
n <- length(y)   # Anzahl der Werte
m <- mean(y)     # Mittelwert
s <- sd(y)       # Standardabweichung

# 1) Standardfehler des Mittelwerts

se_y <- s / sqrt(n)

se_y
```

```
[1] 2.441311
```

```r
# 2) Varianz (Stichprobe)

var_y <- sum((y - m)^2) / (n - 1)

var_y
```

```
[1] 29.8
```

```r
# 3) z-standardisierte Werte

z_y <- (y - m) / s

z_y
```

```
[1]  1.7219468 -0.2930973 -0.4762831 -0.8426548 -0.1099115
```

```r
# 4) 95%-Konfidenzintervall des Mittelwerts

t_crit <- qt(0.975, df = n - 1)

ci_y <- c(
lower = m - t_crit * se_y,
upper = m + t_crit * se_y
)

ci_y
```

```
   lower     upper
6.821834 20.378166
```

**Häufige Fehler**

- Funktion falsch geschrieben: `Mean(y)` statt `mean(y)`
- Klammern vergessen: `mean y` statt `mean(y)`
- `<-` vergessen oder `=` inkonsistent verwendet
- Im falschen Fenster tippen (Konsole statt Skript oder umgekehrt)

## Datentypen & Datenstrukturen

In R ist es wichtig zu wissen, **was für eine Art von Daten** wir vor uns haben und **wie diese Daten organisiert sind**.

Deshalb unterscheiden wir zwischen **Datentypen** und **Datenstrukturen**.

Beides bestimmt, wie wir mit Daten rechnen, sie verändern und analysieren können.

### Wichtige Datentypen

Datentypen legen fest, **welche Art von Werten** in einem Objekt gespeichert ist.
R behandelt Zahlen, Text und logische Werte unterschiedlich – je nach Datentyp.

Der Datentyp ist wichtig, weil er bestimmt, - welche Berechnungen möglich sind - wie R die Werte interpretiert - welche Funktionen sinnvoll angewendet werden können

**Datentypenüberblick**

- `numeric` / `double`
  Zahlen mit Dezimalstellen, z. B. `3.14` oder `-7.5`.
  Wird für die meisten Berechnungen verwendet.
- `integer`
  Ganze Zahlen ohne Dezimalstellen, z. B. `1L` oder `42L`.
  Kommt seltener vor, ist aber wichtig bei Zählvariablen.
- `character`
  Textwerte, z. B. `"Anna"` oder `"Deutschland"`.

Mit Text kann man **nicht rechnen**.

- `logical`
  Logische Werte: `TRUE` oder `FALSE`.
  Wird häufig bei Bedingungen oder Filtern genutzt.

- `factor`
  Kategorische Daten mit festen Ausprägungen, z. B. Geschlecht oder Schulabschluss.

### Wichtige Datenstrukturen

Datenstrukturen beschreiben, **wie mehrere Werte in R zusammengefasst und organisiert** sind.
Sie legen fest, ob Daten einzeln, als einfache Liste oder als Tabelle gespeichert werden.

Welche Datenstruktur wir verwenden, ist wichtig,
weil sie bestimmt, wie wir auf Daten zugreifen, sie verändern und analysieren können.

**Datenstrukturenüberblick**

- **Vektor**
  Eine geordnete Sammlung von Werten **gleichen Datentyps**.
  Grundlage für fast alle anderen Datenstrukturen in R.

- **Matrix**
  Eine rechteckige Tabelle aus Werten **gleichen Datentyps** (meist Zahlen).
  Wird vor allem für mathematische und statistische Berechnungen verwendet.

- **Data Frame / tibble**
  Eine Tabelle mit Zeilen (**Fälle**) und Spalten (**Variablen**).
  Standardformat für Datensätze in der empirischen Forschung.

Datenstrukturen in R bauen in gewisser Weise aufeinander auf.

Am Anfang steht der **Vektor**:
Ein Vektor ist eine einfache, geordnete Reihe von Werten gleichen Datentyps.

Aus Vektoren lassen sich **Matrizen** bilden:
Eine Matrix ist eine Sammlung mehrerer gleich langer Vektoren, die rechteckig angeordnet sind.

Ein **Data Frame** geht einen Schritt weiter:
Auch hier bestehen die Spalten aus Vektoren, die Spalten dürfen aber **unterschiedliche Datentypen** haben.

So lassen sich reale Datensätze mit Zahlen, Text und Kategorien in einer Tabelle abbilden.

**Achtung Wichtig**

Die Datenstrukturen bauen **konzeptionell** aufeinander auf,
sie werden in der Praxis **nicht automatisch ineinander umgewandelt**

---

### Welcher Datentyp oder welche Datenstruktur hat mein Objekt?

In R können wir jederzeit überprüfen, **was für eine Art von Objekt** wir im Environment haben. Das ist besonders hilfreich, wenn wir mit vielen Objekten arbeiten oder unsicher sind, wie R ein Objekt interpretiert.

**Grundlegende Befehle im Überblick**

- `class(x)` - gibt uns eine **allgemeine Einordnung** des Objekts.
  - `typeof(x)` - detaillierter wie class, zeigt **wie R das Objekt intern speichert**
- `str(x)` - gibt einen **Überblick über Aufbau und Inhalt** eines Objekts.

Für **Funktionen**: - `?mean()` - Öffnet die **Hilfeseite** zur Funktion `mean()` (Beschreibung, Argumente, Beispiele).

Im Folgenden betrachten wir unsere zuvor erstellten Objekte `x` und `y` genauer und nutzen sie, **um die entsprechenden Befehle anzuwenden.**

```
class(x)
```

```
[1] "numeric"
```

```
class(y)
```

```
[1] "numeric"
```

```
typeof(x)
```

```
[1] "double"
```

```r
typeof(y)
```

```
[1] "double"
```

```r
str(x)
```

```
 num 5
```

```r
str(y)
```

```
 num [1:5] 23 12 11 9 13
```

**Übung 3** – Datentyp und Datenstruktur

Im bisherigen Verlauf haben wir mehrere **Objekte und Hilfsobjekte** erstellt.

1. Überprüfe für jedes dieser Objekte
   - den **Datentyp** und
   - die **Datenstruktur**.
2. Nutze dafür die Befehle
   `class()`, `typeof()` und `str()`.
3. Überlege dir:
   - Welche Objekte sind **einzelne Werte**?
   - Welche Objekte sind **Vektoren**?

Ziel ist es, ein besseres Gefühl dafür zu bekommen,
wie R unterschiedliche Ergebnisse speichert.

**Lösung – Übung 3**

```r
# Mittelwert
class(m)
```

```
[1] "numeric"
```

```
typeof(m)
```

```
[1] "double"
```

```
str(m)
```

```
 num 13.6
```

```
# Anzahl der Werte
class(n)
```

```
[1] "integer"
```

```
typeof(n)
```

```
[1] "integer"
```

```
str(n)
```

```
 int 5
```

```
# Standardabweichung
class(s)
```

```
[1] "numeric"
```

```
typeof(s)
```

```
[1] "double"
```

```
str(s)
```

```
 num 5.46
```

```
# Standardfehler
class(se_y)
```

```
[1] "numeric"
```

```
typeof(se_y)
```

```
[1] "double"
```

```
str(se_y)
```

```
 num 2.44
```

```
# Varianz
class(var_y)
```

```
[1] "numeric"
```

```
typeof(var_y)
```

```
[1] "double"
```

```
str(var_y)
```

```
 num 29.8
```

```
# z-standardisierte Werte
class(z_y)
```

```
[1] "numeric"
```

```
typeof(z_y)
```

```
[1] "double"
```

```
str(z_y)
```

```
 num [1:5] 1.722 -0.293 -0.476 -0.843 -0.11
```

```
# Konfidenzintervall
class(ci_y)
```

```
[1] "numeric"
```

```r
typeof(ci_y)
```

```
[1] "double"
```

```r
str(ci_y)
```

```
 Named num [1:2] 6.82 20.38
 - attr(*, "names")= chr [1:2] "lower" "upper"
```

**Faustregel: Ein Objekt in R verstehen**

1. `class()`
   → Welche **Art von Objekt** ist es?
2. `typeof()`
   → Wie wird das Objekt **intern gespeichert**?
3. `str()`
   → Wie ist das Objekt **aufgebaut** und welche Inhalte hat es?

### Einen ersten Datensatz in R erstellen

Bisher haben wir mit einzelnen Objekten und Vektoren gearbeitet. In der Praxis bestehen Datensätze jedoch aus **mehreren Variablen**, die gemeinsam eine Gruppe von Fällen beschreiben.

Im nächsten Schritt erstellen wir deshalb mehrere Vektoren (z. B. Alter, Geschlecht oder Körpergröße) und führen sie zu einem **kleinen Datensatz** zusammen.

Dabei lernst du, - wie mehrere Vektoren sinnvoll angelegt werden und
- wie aus einzelnen Variablen eine tabellarische Struktur entsteht.

Wir legen nun unsere neuen Vektoren (= **Variablen**)** an:

```r
# Alter
age <- c(23, 29, 35, 41, 27, 33)

# Geschlecht
gender <- c("female", "male", "female", "male", "female", "male")

# Haarfarbe
hair_color <- c("brown", "blonde", "black", "brown", "red", "black")
```

```r
# Körpergröße in cm
height_cm <- c(165, 180, 172, 178, 160, 185)

# Gewicht in kg
weight_kg <- c(60, 82, 70, 88, 55, 90)

# Beruf
occupation <- c(
  "student",
  "engineer",
  "teacher",
  "manager",
  "student",
  "researcher"
)
```

Jeder dieser Vektoren stellt eine **Variable** dar.
Die einzelnen Werte gehören jeweils **zur gleichen Person**
(d. h. zur gleichen Zeile im späteren Datensatz).

> **!** Wichtig
>
> Alle Vektoren müssen **die gleiche Länge** haben.
> Überprüfe das!

Im nächsten Schritt fassen wir die einzelnen Variablen zu einem **gemeinsamen Datensatz** zusammen.
Dabei verwenden wir zunächst **Base R**, also Funktionen, die ohne zusätzliche Pakete verfügbar sind.

```r
data <- data.frame(
  age = age,
  gender = gender,
  hair_color = hair_color,
  height_cm = height_cm,
  weight_kg = weight_kg,
  occupation = occupation
)

data
```

```
  age gender hair_color height_cm weight_kg occupation
```

```
1  23 female      brown       165        60    student
2  29   male     blonde       180        82   engineer
3  35 female      black       172        70    teacher
4  41   male      brown       178        88    manager
5  27 female        red       160        55    student
6  33   male      black       185        90 researcher
```

**Achtung**

Aufbau der Funktion `data.frame()`:
`data.frame(name1 = name2)`

- `name1` = Spaltenname im Datensatz
- `name2` = Objektname aus dem Environment

Die einzelnen Vektoren sind nun zu einem **Datensatz** zusammengeführt worden:

- jede **Spalte** ist eine Variable
- jede **Zeile** ist ein Fall (eine Person)

`data.frame()` ist die klassische Tabellenstruktur in Base R
und bildet die Grundlage für viele weitere Analyseschritte.

**Erinnerung**

Auch ein einzelner Wert ist in R ein **Vektor der Länge 1**. Mit der `c()` Funktion können wir einzelne Werte zu einem Vektor zusammenfassen

**Übung 4** – Erstelle einen Datensatz

Bisher haben wir einen Datensatz erstellt mit sechs Variablen. Erstelle nun zwei weitere **Variablen** und füge diesen zu einem Datensatz hinzu. Nenne die eine Variable `numbers`und die andere `chars`.

**Lösung - Übung 4**

```r
numbers <- c(12,5,17,6,75,22)

chars <- c("Anna", "Alex", "Beate", "Bobby", "Christina", "Chester")

data <- data.frame(
  age = age,
  gender = gender,
  hair_color = hair_color,
  height_cm = height_cm,
  weight_kg = weight_kg,
  occupation = occupation,
  nmbrs = numbers,
  chars = chars
)
```

**Typische Fehler beim Erstellen eines Data Frames**

- **Komma vergessen oder zu viel gesetzt**
  → führt oft zu unerwarteten Fehlermeldungen.
- **Falscher Objektname**
  → R unterscheidet zwischen Groß- und Kleinschreibung
  (`Age` ≠ `age`).
- **Unterschiedliche Längen der Vektoren**
  → Alle Variablen müssen **gleich viele Werte** haben.

### Exkurs: Pakete

Pakete sind **Erweiterungen von R**.
Sie enthalten zusätzliche Funktionen, Datensätze und Dokumentationen,
die bestimmte Aufgaben erleichtern oder überhaupt erst möglich machen.

R bringt bereits viele grundlegende Funktionen mit (Base R).
Für komplexere oder spezialisierte Aufgaben greifen wir jedoch häufig auf **Pakete** zurück.

### Pakete Installieren

Bevor wir ein Paket nutzen können, müssen wir es **einmal installieren**.
Die Installation erfolgt über das Internet und wird lokal auf dem Rechner gespeichert.

```
install.packages("tidyverse")
install.packages("psych")
```

> **Wichtig**
>
> `install.packages()` muss **nur einmal** ausgeführt werden.
> Danach ist das Paket in der Regel dauerhaft auf deinem Rechner verfügbar.

### Paket laden

Nach der Installation müssen Pakete **in jeder neuen R-Sitzung geladen** werden, damit ihre Funktionen zur Verfügung stehen.

```
library(tidyverse)
library(psych)
```

> **Merksatz**
>
> - `install.packages()` → einmal installieren
> - `library()` → in jeder Sitzung laden

### Das tidyverse

Das **tidyverse** ist eine Sammlung mehrerer Pakete,
die besonders für **Datenaufbereitung, Analyse und Visualisierung** entwickelt wurden.

Es bietet:

- gut lesbaren Code
- einheitliche Funktionsnamen
- komfortable Werkzeuge für Data Frames

> **Tip**
>
> Typische tidyverse-Pakete sind zum Beispiel:
>
> - `dplyr` (Datenaufbereitung)
> - `ggplot2` (Visualisierung)
> - `readr` (Datenimport)

Wir werden das tidyverse später als **Alternative zu Base R** nutzen.

### Das psych-Paket

Das Paket **psych** wird häufig in den Sozial- und Verhaltenswissenschaften verwendet.

Es enthält unter anderem:

- deskriptive Statistiken
- Skalenanalysen
- psychometrische Kennwerte

> **Note**
>
> `psych` ergänzt Base R um viele Funktionen, die in der empirischen Forschung regelmäßig benötigt werden.

## Datenimport

Bisher haben wir Datensätze selbst erstellt, um zu verstehen,
wie Daten in R **strukturiert** sind (Vektoren, Data Frames, Variablen).

In der Praxis müssen wir Datensätze jedoch **nicht von Hand anlegen**.
Häufig stammen Daten aus externen Quellen, zum Beispiel aus:

- Online-Befragungstools (z. B. SoSci Survey)
- Excel-Tabellen
- Statistiksoftware wie SPSS
- Forschungsprojekten oder Repositorien

Diese Daten werden meist über eine **Export-Funktion** als Datei bereitgestellt (z. B. CSV oder Excel) und anschließend in R **importiert**.

**Typische Datenformate**

- **CSV** (`.csv`) – sehr verbreitet, einfach, textbasiert
- **Excel** (`.xlsx`) – häufig in der Praxis
- **SPSS** (`.sav`) – vor allem in den Sozialwissenschaften

Beim Importieren von Daten können verschiedene **Hürden** auftreten.
Diese sind normal und gehören zur Arbeit mit realen Datensätzen dazu.

**Typische Probleme beim Datenimport**

- Datei wird nicht gefunden (falscher **Pfad**)
- Falsches **Trennzeichen** (Komma vs. Semikolon)
- Umlaute oder Sonderzeichen werden falsch angezeigt (**Encoding**)
- Variablen werden als Text statt als Zahl erkannt
- Fehlende Werte sind unterschiedlich kodiert (z. B. leer, `-99`, `999`)

Um den Datenimport möglichst übersichtlich und zuverlässig zu gestalten,
verwenden wir ab jetzt Funktionen aus dem **tidyverse**.

Diese bieten: - klare und gut lesbare Befehle
- sinnvolle Standardannahmen
- eine einfache erste Prüfung der importierten Daten

**Einordnung**

Wir haben bewusst zuerst mit **Base R** gearbeitet,
um die grundlegenden Strukturen zu verstehen.
Jetzt nutzen wir das tidyverse als **komfortablere Alternative**
für reale Daten und typische Workflows.

Im nächsten Schritt importieren wir einen Datensatz aus einer SAV-Datei
und prüfen anschließend, ob der Import korrekt funktioniert hat.

Für die folgenden Schritte arbeiten wir mit einem **vorgegebenen Datensatz**.

Bitte lade den Datensatz herunter und speichere ihn **in deinem Projektordner**, zum Beispiel im Unterordner `data/`.

**Workshop-Datensatz herunterladen (CSV)**
**Workshop-Datensatz herunterladen (SPSS)**

Hier kannst du das **Codebuch** zum Datensatz runterladen, für eine **bessere Übersicht**, über die Variablen im Datensatz.

**Codebuch Workshop Datensatz (PDF)**

**Wichtig**

Achte darauf, die Datei **nicht irgendwo auf dem Rechner**, sondern **im Projektordner** zu speichern.
Nur so funktionieren die folgenden Import-Befehle ohne Probleme.

Jetzt importieren wir die Daten.

```
# Falls nicht schon geschehen, lade folgende Pakete:

library(tidyverse)
library(haven)

# Importiere nun die Datensätz

df_csv <- read_csv("assets/data/datensatz_workshop.csv")

df_spss <- read_sav("assets/data/spss_datensatz_workshop.sav")
```

Hinweis

Was fällt dir auf, wenn du die **Datensätze** vergleichst?

**Typische Probleme & Lösungen**

| Problem | Mögliche Ursache | Mögliche Lösung |
|---|---|---|
| `cannot open file` | falscher Pfad | Projektordner prüfen, Datei-Pfad anpassen |
| Umlaute „kaputt“ | Encoding | `locale = locale(encoding = "UTF-8")` testen |
| alles `character` | Typ falsch erkannt | nachträglich mit `mutate()` umwandeln |

## Datenaufbereitung

Nachdem wir den Datensatz erfolgreich importiert haben, beginnt ein zentraler Schritt der Datenanalyse: die **Datenaufbereitung**.

Daten liegen in der Praxis selten sofort in der Form vor, in der sie analysiert oder ausgewertet werden können. Häufig müssen Variablen ausgewählt, Fälle gefiltert, Werte umkodiert oder neue Variablen erstellt werden.

Für diese Arbeitsschritte verwenden wir das Paket **dplyr**.

### Überblick Datensatz

Bevor wir Daten aufbereiten oder verändern, sollten wir uns immer zuerst einen **Überblick über den Datensatz** verschaffen.

So können wir prüfen, - ob die Daten korrekt importiert wurden, - welche Variablen enthalten sind, - welche Datentypen vorliegen, - und ob es offensichtliche Auffälligkeiten gibt.

### Schneller Überblick

```
summary(df_csv)

summary(df_spss)
```

**Output**

```
summary(df_csv)
```

```
   eastwest         german           sex             age
 Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :18.00
 1st Qu.:1.000   1st Qu.:1.000   1st Qu.:1.000   1st Qu.:39.00
 Median :1.000   Median :1.000   Median :2.000   Median :55.00
 Mean   :1.334   Mean   :1.114   Mean   :1.509   Mean   :53.27
 3rd Qu.:2.000   3rd Qu.:1.000   3rd Qu.:2.000   3rd Qu.:67.00
 Max.   :2.000   Max.   :3.000   Max.   :3.000   Max.   :96.00
                 NA's   :30      NA's   :20      NA's   :41
     agec            dg10            dg03            educ          isced97
 Min.   :1.000   Min.   : 1.00   Min.   :1.000   Min.   :1.00   Min.   :1.000
 1st Qu.:2.000   1st Qu.: 6.00   1st Qu.:1.000   1st Qu.:3.00   1st Qu.:3.000
 Median :3.000   Median : 8.00   Median :4.000   Median :3.00   Median :4.000
 Mean   :3.077   Mean   :14.44   Mean   :2.947   Mean   :3.65   Mean   :3.996
```

```
3rd Qu.:4.000   3rd Qu.:15.00   3rd Qu.:4.000   3rd Qu.:5.00   3rd Qu.:5.000
Max.   :6.000   Max.   :95.00   Max.   :4.000   Max.   :7.00   Max.   :6.000
NA's   :41      NA's   :30      NA's   :420     NA's   :170    NA's   :69
    iscd11          work          isco08        siops08          isei08
Min.   :1.000   Min.   :1.00   Min.   : 110   Min.   :13.00   Min.   :11.74
1st Qu.:3.000   1st Qu.:1.00   1st Qu.:2423   1st Qu.:42.09   1st Qu.:36.92
Median :4.000   Median :2.00   Median :3322   Median :48.37   Median :54.55
Mean   :4.574   Mean   :2.38   Mean   :3928   Mean   :47.93   Mean   :53.03
3rd Qu.:7.000   3rd Qu.:4.00   3rd Qu.:5153   3rd Qu.:54.64   3rd Qu.:70.34
Max.   :8.000   Max.   :4.00   Max.   :9629   Max.   :78.16   Max.   :88.96
NA's   :69      NA's   :56     NA's   :2642   NA's   :2642    NA's   :2642
     dw15            dw16           dw19c           dw03          mstat
Min.   : 4.00   Min.   :1.000   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:35.00   1st Qu.:1.000   1st Qu.:3.000   1st Qu.:2.00   1st Qu.:1.000
Median :40.00   Median :1.000   Median :4.000   Median :2.00   Median :1.000
Mean   :38.53   Mean   :1.212   Mean   :3.778   Mean   :2.29   Mean   :2.449
3rd Qu.:42.00   3rd Qu.:1.000   3rd Qu.:5.000   3rd Qu.:2.00   3rd Qu.:5.000
Max.   :87.50   Max.   :3.000   Max.   :6.000   Max.   :6.00   Max.   :9.000
NA's   :2414    NA's   :2705    NA's   :4811    NA's   :3091   NA's   :136
     dp01            di01a           di02a           incc
Min.   :1.000   Min.   :   20   Min.   : 1.00   Min.   : 1.00
1st Qu.:1.000   1st Qu.: 1450   1st Qu.: 9.00   1st Qu.:10.00
Median :2.000   Median : 2200   Median :13.00   Median :14.00
Mean   :1.557   Mean   : 2461   Mean   :13.04   Mean   :13.57
3rd Qu.:2.000   3rd Qu.: 3000   3rd Qu.:16.00   3rd Qu.:17.00
Max.   :2.000   Max.   :15000   Max.   :26.00   Max.   :26.00
NA's   :3139    NA's   :4141    NA's   :1994    NA's   :793
    di01b           di02b           di05            di06
Min.   :  446   Min.   : 1.00   Min.   :  390   Min.   : 1.00
1st Qu.: 3000   1st Qu.:16.00   1st Qu.: 2400   1st Qu.:14.00
Median : 4000   Median :19.00   Median : 3500   Median :18.00
Mean   : 4602   Mean   :18.77   Mean   : 4050   Mean   :17.43
3rd Qu.: 5500   3rd Qu.:22.00   3rd Qu.: 5000   3rd Qu.:21.00
Max.   :50000   Max.   :26.00   Max.   :50000   Max.   :26.00
NA's   :4511    NA's   :2856    NA's   :4257    NA's   :2141
    hhincc          dh01            dh11            aq01
Min.   : 1.00   Min.   :1.000   Min.   :1.000   Min.   :1.000
1st Qu.:15.00   1st Qu.:1.000   1st Qu.:1.000   1st Qu.:4.000
Median :19.00   Median :1.000   Median :1.000   Median :6.000
Mean   :17.85   Mean   :1.218   Mean   :1.713   Mean   :5.469
3rd Qu.:21.00   3rd Qu.:1.000   3rd Qu.:2.000   3rd Qu.:7.000
```

```
Max.   :26.00   Max.   :2.000   Max.   :9.000   Max.   :8.000
NA's   :1056    NA's   :153     NA's   :1300    NA's   :199
     gs01            gd01            gd02            dg13            dg08
Min.   :1.000   Min.   :1935   Min.   : 0.00   Min.   :1.000   Min.   :1.00
1st Qu.:2.000   1st Qu.:1994   1st Qu.:10.00   1st Qu.:1.000   1st Qu.:1.00
Median :3.000   Median :2011   Median :25.00   Median :2.000   Median :2.00
Mean   :2.748   Mean   :3746   Mean   :29.47   Mean   :2.529   Mean   :1.64
3rd Qu.:4.000   3rd Qu.:2021   3rd Qu.:46.00   3rd Qu.:4.000   3rd Qu.:2.00
Max.   :5.000   Max.   :9000   Max.   :93.00   Max.   :6.000   Max.   :2.00
NA's   :142     NA's   :1953   NA's   :1958    NA's   :2845    NA's   :3095
     dg09            dg11            ls01            id02
Min.   :1.000   Min.   :1.000   Min.   : 0.000   Min.   :1.000
1st Qu.:1.000   1st Qu.:1.000   1st Qu.: 6.000   1st Qu.:2.000
Median :2.000   Median :2.000   Median : 8.000   Median :3.000
Mean   :1.638   Mean   :1.611   Mean   : 7.256   Mean   :2.883
3rd Qu.:2.000   3rd Qu.:2.000   3rd Qu.: 8.000   3rd Qu.:3.000
Max.   :2.000   Max.   :2.000   Max.   :10.000   Max.   :5.000
NA's   :4229    NA's   :1938    NA's   :196      NA's   :201
     id01            im01            im17            im18            im19
Min.   :1.000   Min.   :1.00   Min.   :1.000   Min.   :1.000   Min.   :1.000
1st Qu.:2.000   1st Qu.:1.00   1st Qu.:2.000   1st Qu.:2.000   1st Qu.:2.000
Median :3.000   Median :2.00   Median :2.000   Median :2.000   Median :3.000
Mean   :2.599   Mean   :1.54   Mean   :2.347   Mean   :2.487   Mean   :2.683
3rd Qu.:3.000   3rd Qu.:2.00   3rd Qu.:3.000   3rd Qu.:3.000   3rd Qu.:3.000
Max.   :4.000   Max.   :2.00   Max.   :4.000   Max.   :4.000   Max.   :4.000
NA's   :213     NA's   :1864   NA's   :102     NA's   :106     NA's   :166
     im20            im21            iw04            pd11            pi07
Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:2.000   1st Qu.:2.000   1st Qu.:1.000   1st Qu.:1.00   1st Qu.:1.000
Median :3.000   Median :3.000   Median :1.000   Median :2.00   Median :1.000
Mean   :2.708   Mean   :2.944   Mean   :1.572   Mean   :1.63   Mean   :1.493
3rd Qu.:3.000   3rd Qu.:4.000   3rd Qu.:2.000   3rd Qu.:2.00   3rd Qu.:2.000
Max.   :4.000   Max.   :4.000   Max.   :4.000   Max.   :4.00   Max.   :2.000
NA's   :152     NA's   :112     NA's   :74      NA's   :81     NA's   :1923
     pi01            pi02            lp03            lp04            lp05
Min.   :1.000   Min.   :1.00   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:1.000   1st Qu.:2.00   1st Qu.:1.000   1st Qu.:1.00   1st Qu.:1.000
Median :1.000   Median :2.00   Median :1.000   Median :2.00   Median :1.000
Mean   :1.155   Mean   :2.21   Mean   :1.297   Mean   :1.68   Mean   :1.269
3rd Qu.:1.000   3rd Qu.:3.00   3rd Qu.:2.000   3rd Qu.:2.00   3rd Qu.:2.000
Max.   :2.000   Max.   :3.00   Max.   :2.000   Max.   :2.00   Max.   :2.000
```

```
NA's   :54      NA's   :894    NA's   :210     NA's   :178    NA's   :160
     lp06            hs01            hs04            hs05
Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :1.000
1st Qu.:1.000   1st Qu.:2.000   1st Qu.:2.000   1st Qu.:3.000
Median :1.000   Median :2.000   Median :3.000   Median :3.000
Mean   :1.376   Mean   :2.437   Mean   :3.036   Mean   :3.356
3rd Qu.:2.000   3rd Qu.:3.000   3rd Qu.:4.000   3rd Qu.:4.000
Max.   :2.000   Max.   :5.000   Max.   :5.000   Max.   :5.000
NA's   :164     NA's   :63      NA's   :1793    NA's   :1792
     hs06            hs07            hs09            land
Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   : 10.00
1st Qu.:2.000   1st Qu.:2.000   1st Qu.:3.000   1st Qu.: 50.00
Median :2.000   Median :3.000   Median :4.000   Median : 80.00
Mean   :2.614   Mean   :2.921   Mean   :4.044   Mean   : 86.99
3rd Qu.:3.000   3rd Qu.:3.000   3rd Qu.:5.000   3rd Qu.:120.00
Max.   :5.000   Max.   :5.000   Max.   :5.000   Max.   :160.00
NA's   :1797    NA's   :1805    NA's   :1791
     bik             gkpol
Min.   : 1.00   Min.   :1.000
1st Qu.: 5.00   1st Qu.:3.000
Median : 8.00   Median :4.000
Mean   : 7.07   Mean   :4.313
3rd Qu.:10.00   3rd Qu.:6.000
Max.   :10.00   Max.   :7.000
NA's   :174     NA's   :68
```

```
summary(df_spss)
```

```
   eastwest        german          sex             age
Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :18.00
1st Qu.:1.000   1st Qu.:1.000   1st Qu.:1.000   1st Qu.:39.00
Median :1.000   Median :1.000   Median :2.000   Median :55.00
Mean   :1.334   Mean   :1.114   Mean   :1.509   Mean   :53.27
3rd Qu.:2.000   3rd Qu.:1.000   3rd Qu.:2.000   3rd Qu.:67.00
Max.   :2.000   Max.   :3.000   Max.   :3.000   Max.   :96.00
                NA's   :30      NA's   :20      NA's   :41
     agec            dg10            dg03            educ          isced97
Min.   :1.000   Min.   : 1.00   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:2.000   1st Qu.: 6.00   1st Qu.:1.000   1st Qu.:3.00   1st Qu.:3.000
Median :3.000   Median : 8.00   Median :4.000   Median :3.00   Median :4.000
Mean   :3.077   Mean   :14.44   Mean   :2.947   Mean   :3.65   Mean   :3.996
3rd Qu.:4.000   3rd Qu.:15.00   3rd Qu.:4.000   3rd Qu.:5.00   3rd Qu.:5.000
```

```
Max.   :6.000   Max.   :95.00   Max.   :4.000   Max.   :7.00   Max.   :6.000
NA's   :41      NA's   :30      NA's   :420     NA's   :170    NA's   :69
    iscd11          work          isco08         siops08          isei08
Min.   :1.000   Min.   :1.00   Min.   : 110   Min.   :13.00   Min.   :11.74
1st Qu.:3.000   1st Qu.:1.00   1st Qu.:2423   1st Qu.:42.09   1st Qu.:36.92
Median :4.000   Median :2.00   Median :3322   Median :48.37   Median :54.55
Mean   :4.574   Mean   :2.38   Mean   :3928   Mean   :47.93   Mean   :53.03
3rd Qu.:7.000   3rd Qu.:4.00   3rd Qu.:5153   3rd Qu.:54.64   3rd Qu.:70.34
Max.   :8.000   Max.   :4.00   Max.   :9629   Max.   :78.16   Max.   :88.96
NA's   :69      NA's   :56     NA's   :2642   NA's   :2642    NA's   :2642
     dw15            dw16           dw19c           dw03          mstat
Min.   : 4.00   Min.   :1.000   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:35.00   1st Qu.:1.000   1st Qu.:3.000   1st Qu.:2.00   1st Qu.:1.000
Median :40.00   Median :1.000   Median :4.000   Median :2.00   Median :1.000
Mean   :38.53   Mean   :1.212   Mean   :3.778   Mean   :2.29   Mean   :2.449
3rd Qu.:42.00   3rd Qu.:1.000   3rd Qu.:5.000   3rd Qu.:2.00   3rd Qu.:5.000
Max.   :87.50   Max.   :3.000   Max.   :6.000   Max.   :6.00   Max.   :9.000
NA's   :2414    NA's   :2705    NA's   :4811    NA's   :3091   NA's   :136
     dp01            di01a           di02a           incc
Min.   :1.000   Min.   :   20   Min.   : 1.00   Min.   : 1.00
1st Qu.:1.000   1st Qu.: 1450   1st Qu.: 9.00   1st Qu.:10.00
Median :2.000   Median : 2200   Median :13.00   Median :14.00
Mean   :1.557   Mean   : 2461   Mean   :13.04   Mean   :13.57
3rd Qu.:2.000   3rd Qu.: 3000   3rd Qu.:16.00   3rd Qu.:17.00
Max.   :2.000   Max.   :15000   Max.   :26.00   Max.   :26.00
NA's   :3139    NA's   :4141    NA's   :1994    NA's   :793
    di01b           di02b           di05            di06
Min.   :  446   Min.   : 1.00   Min.   :  390   Min.   : 1.00
1st Qu.: 3000   1st Qu.:16.00   1st Qu.: 2400   1st Qu.:14.00
Median : 4000   Median :19.00   Median : 3500   Median :18.00
Mean   : 4602   Mean   :18.77   Mean   : 4050   Mean   :17.43
3rd Qu.: 5500   3rd Qu.:22.00   3rd Qu.: 5000   3rd Qu.:21.00
Max.   :50000   Max.   :26.00   Max.   :50000   Max.   :26.00
NA's   :4511    NA's   :2856    NA's   :4257    NA's   :2141
    hhincc          dh01            dh11            aq01
Min.   : 1.00   Min.   :1.000   Min.   :1.000   Min.   :1.000
1st Qu.:15.00   1st Qu.:1.000   1st Qu.:1.000   1st Qu.:4.000
Median :19.00   Median :1.000   Median :1.000   Median :6.000
Mean   :17.85   Mean   :1.218   Mean   :1.713   Mean   :5.469
3rd Qu.:21.00   3rd Qu.:1.000   3rd Qu.:2.000   3rd Qu.:7.000
Max.   :26.00   Max.   :2.000   Max.   :9.000   Max.   :8.000
```

```
NA's   :1056    NA's   :153     NA's   :1300    NA's   :199
     gs01            gd01            gd02            dg13            dg08
Min.   :1.000   Min.   :1935   Min.   : 0.00   Min.   :1.000   Min.   :1.00
1st Qu.:2.000   1st Qu.:1994   1st Qu.:10.00   1st Qu.:1.000   1st Qu.:1.00
Median :3.000   Median :2011   Median :25.00   Median :2.000   Median :2.00
Mean   :2.748   Mean   :3746   Mean   :29.47   Mean   :2.529   Mean   :1.64
3rd Qu.:4.000   3rd Qu.:2021   3rd Qu.:46.00   3rd Qu.:4.000   3rd Qu.:2.00
Max.   :5.000   Max.   :9000   Max.   :93.00   Max.   :6.000   Max.   :2.00
NA's   :142     NA's   :1953   NA's   :1958    NA's   :2845    NA's   :3095
     dg09            dg11            ls01            id02
Min.   :1.000   Min.   :1.000   Min.   : 0.000   Min.   :1.000
1st Qu.:1.000   1st Qu.:1.000   1st Qu.: 6.000   1st Qu.:2.000
Median :2.000   Median :2.000   Median : 8.000   Median :3.000
Mean   :1.638   Mean   :1.611   Mean   : 7.256   Mean   :2.883
3rd Qu.:2.000   3rd Qu.:2.000   3rd Qu.: 8.000   3rd Qu.:3.000
Max.   :2.000   Max.   :2.000   Max.   :10.000   Max.   :5.000
NA's   :4229    NA's   :1938    NA's   :196      NA's   :201
     id01            im01            im17            im18            im19
Min.   :1.000   Min.   :1.00   Min.   :1.000   Min.   :1.000   Min.   :1.000
1st Qu.:2.000   1st Qu.:1.00   1st Qu.:2.000   1st Qu.:2.000   1st Qu.:2.000
Median :3.000   Median :2.00   Median :2.000   Median :2.000   Median :3.000
Mean   :2.599   Mean   :1.54   Mean   :2.347   Mean   :2.487   Mean   :2.683
3rd Qu.:3.000   3rd Qu.:2.00   3rd Qu.:3.000   3rd Qu.:3.000   3rd Qu.:3.000
Max.   :4.000   Max.   :2.00   Max.   :4.000   Max.   :4.000   Max.   :4.000
NA's   :213     NA's   :1864   NA's   :102     NA's   :106     NA's   :166
     im20            im21            iw04            pd11            pi07
Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:2.000   1st Qu.:2.000   1st Qu.:1.000   1st Qu.:1.00   1st Qu.:1.000
Median :3.000   Median :3.000   Median :1.000   Median :2.00   Median :1.000
Mean   :2.708   Mean   :2.944   Mean   :1.572   Mean   :1.63   Mean   :1.493
3rd Qu.:3.000   3rd Qu.:4.000   3rd Qu.:2.000   3rd Qu.:2.00   3rd Qu.:2.000
Max.   :4.000   Max.   :4.000   Max.   :4.000   Max.   :4.00   Max.   :2.000
NA's   :152     NA's   :112     NA's   :74      NA's   :81     NA's   :1923
     pi01            pi02            lp03            lp04            lp05
Min.   :1.000   Min.   :1.00   Min.   :1.000   Min.   :1.00   Min.   :1.000
1st Qu.:1.000   1st Qu.:2.00   1st Qu.:1.000   1st Qu.:1.00   1st Qu.:1.000
Median :1.000   Median :2.00   Median :1.000   Median :2.00   Median :1.000
Mean   :1.155   Mean   :2.21   Mean   :1.297   Mean   :1.68   Mean   :1.269
3rd Qu.:1.000   3rd Qu.:3.00   3rd Qu.:2.000   3rd Qu.:2.00   3rd Qu.:2.000
Max.   :2.000   Max.   :3.00   Max.   :2.000   Max.   :2.00   Max.   :2.000
NA's   :54      NA's   :894    NA's   :210     NA's   :178    NA's   :160
```

```
      lp06            hs01            hs04            hs05
 Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   :1.000
 1st Qu.:1.000   1st Qu.:2.000   1st Qu.:2.000   1st Qu.:3.000
 Median :1.000   Median :2.000   Median :3.000   Median :3.000
 Mean   :1.376   Mean   :2.437   Mean   :3.036   Mean   :3.356
 3rd Qu.:2.000   3rd Qu.:3.000   3rd Qu.:4.000   3rd Qu.:4.000
 Max.   :2.000   Max.   :5.000   Max.   :5.000   Max.   :5.000
 NA's   :164     NA's   :63      NA's   :1793    NA's   :1792
      hs06            hs07            hs09            land
 Min.   :1.000   Min.   :1.000   Min.   :1.000   Min.   : 10.00
 1st Qu.:2.000   1st Qu.:2.000   1st Qu.:3.000   1st Qu.: 50.00
 Median :2.000   Median :3.000   Median :4.000   Median : 80.00
 Mean   :2.614   Mean   :2.921   Mean   :4.044   Mean   : 86.99
 3rd Qu.:3.000   3rd Qu.:3.000   3rd Qu.:5.000   3rd Qu.:120.00
 Max.   :5.000   Max.   :5.000   Max.   :5.000   Max.   :160.00
 NA's   :1797    NA's   :1805    NA's   :1791
      bik             gkpol
 Min.   : 1.00   Min.   :1.000
 1st Qu.: 5.00   1st Qu.:3.000
 Median : 8.00   Median :4.000
 Mean   : 7.07   Mean   :4.313
 3rd Qu.:10.00   3rd Qu.:6.000
 Max.   :10.00   Max.   :7.000
 NA's   :174     NA's   :68
```

`summary()` gibt uns eine erste **Zusammenfassung der Variablen** (z. B. Min/Max-Werte, Mittelwerte, Häufigkeiten). Aber es wirkt sehr unübersichtlich, daher verwenden wir **`glimpse()`**.

```
glimpse(df_csv)

glimpse(df_spss)
```

**Output**

```
glimpse(df_csv)

Rows: 5,342
Columns: 65
$ eastwest <dbl> 1, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 2, 2, 1, 1, 1, 1, 1, 1, 1~
$ german   <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 3, 1, 1, 3, 3, 1, 1, 1, 1, 1~
$ sex      <dbl> 2, 1, 2, 1, 2, 1, 2, 2, 1, 2, 1, 1, 2, 1, 1, 2, 1, 1, 1, 2~
```

```
$ age      <dbl> 54, 53, 89, 79, 62, 23, 31, 57, 68, 51, 57, 85, 55, 26, 38, 5~
$ agec     <dbl> 3, 3, 5, 5, 4, 1, 2, 3, 4, 3, 3, 5, 3, 1, 2, 3, 3, 3, 3, 1, 5~
$ dg10     <dbl> 1, 8, 7, 17, 8, 2, 8, 12, 17, 7, 95, 17, 15, 95, 95, 8, 9, 7,~
$ dg03     <dbl> 4, 4, 4, 1, 4, 4, 4, 2, 1, 4, NA, 1, 1, NA, NA, 4, 4, 4, 4, 4~
$ educ     <dbl> 5, 5, 4, 4, 2, 7, 5, 4, 3, 3, NA, 5, 3, 2, NA, 3, 2, 5, 2, 5,~
$ isced97  <dbl> 5, 5, 4, 5, 3, NA, 6, 5, 5, 3, 5, 5, 5, 5, 5, 5, 3, 5, 3, 5, ~
$ iscd11   <dbl> 5, 6, 4, 5, 3, NA, 8, 5, 7, 3, 5, 7, 5, 5, 6, 5, 3, 7, 3, 7, ~
$ work     <dbl> 1, 1, 4, 4, 4, 4, 2, 1, 4, 2, 4, 4, 2, 1, 1, 2, 1, 2, 1, 1, 4~
$ isco08   <dbl> 5244, 2421, NA, NA, NA, NA, 2310, 4110, NA, 3221, NA, NA, 341~
$ siops08  <dbl> 26.00, 55.80, NA, NA, NA, NA, 78.16, 42.09, NA, 44.00, NA, NA~
$ isei08   <dbl> 38.88, 70.09, NA, NA, NA, NA, 85.41, 43.33, NA, 56.00, NA, NA~
$ dw15     <dbl> 35.0, 62.0, NA, NA, NA, NA, 32.0, 39.5, NA, 30.0, NA, NA, 33.~
$ dw16     <dbl> 1, NA, NA, NA, NA, NA, 2, 1, NA, 1, NA, NA, 1, NA, 1, 1, 3, 1~
$ dw19c    <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ dw03     <dbl> NA, NA, 2, 2, 4, 1, NA, NA, 2, NA, 3, 2, NA, NA, NA, NA, NA, ~
$ mstat    <dbl> 5, 5, 3, 1, 1, 5, 5, 1, 1, 5, 3, 1, 1, 5, 4, 1, 4, 1, 5, 5, 3~
$ dp01     <dbl> 1, 2, 2, NA, NA, 1, 1, NA, NA, 1, 2, NA, NA, 2, 2, NA, 1, NA,~
$ di01a    <dbl> NA, NA, NA, NA, NA, NA, 1900, NA, 1300, NA, 356, NA, NA, NA, ~
$ di02a    <dbl> 10, 19, NA, 12, NA, NA, NA, 15, NA, 13, NA, 16, 13, 14, 16, 1~
$ incc     <dbl> 10, 19, NA, 12, NA, NA, 14, 15, 11, 13, 3, 16, 13, 14, 16, 13~
$ di01b    <dbl> NA, NA, NA, NA, NA, NA, 5000, NA, 1900, NA, NA, NA, NA, NA, N~
$ di02b    <dbl> NA, NA, NA, 15, 19, 12, NA, 20, NA, NA, 3, 19, 19, NA, NA, 15~
$ di05     <dbl> NA, NA, NA, NA, NA, NA, 5000, NA, 1900, NA, NA, NA, NA, NA, N~
$ di06     <dbl> 10, 19, NA, 15, 19, 12, NA, 20, NA, NA, 3, 19, 19, 14, 16, 15~
$ hhincc   <dbl> 10, 19, NA, 15, 19, 12, 23, 20, 14, NA, 3, 19, 19, 14, 16, 15~
$ dh01     <dbl> 2, 2, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 1, 1, 1, 2, 2, 2~
$ dh11     <dbl> NA, NA, NA, 1, 2, 1, 2, 1, 1, 4, 3, 1, 1, NA, NA, 2, 1, 3, NA~
$ aq01     <dbl> 4, 7, 8, 7, 7, 4, 4, 7, 5, 7, 6, NA, 7, 4, 3, 7, 7, 7, 4, 4, ~
$ gs01     <dbl> 4, 3, 3, 3, 4, 1, 1, 4, 3, 4, 4, 3, 4, 4, 1, 1, 4, 1, 3, 1, 2~
$ gd01     <dbl> NA, 9000, 2011, NA, NA, NA, 2012, NA, 1975, NA, NA, 1962, NA,~
$ gd02     <dbl> NA, 53, 10, NA, NA, NA, 9, NA, 46, NA, NA, 59, NA, NA, NA, 58~
$ dg13     <dbl> NA, NA, 5, NA, NA, NA, 6, NA, 1, NA, NA, 5, NA, NA, NA, NA, 1~
$ dg08     <dbl> NA, 1, 2, NA, NA, NA, 1, NA, NA, NA, NA, NA, NA, NA, NA, 2, 1~
$ dg09     <dbl> NA, NA, NA, NA, NA, NA, NA, NA, 2, NA, NA, 1, NA, NA, NA, NA,~
$ dg11     <dbl> NA, 1, 2, NA, NA, NA, 1, NA, 2, NA, NA, 1, NA, NA, NA, 1, 2, ~
$ ls01     <dbl> 8, 10, 9, 9, 8, 8, 7, 5, 5, 9, 6, 7, 7, 8, 6, 5, 7, 7, 7, 6, ~
$ id02     <dbl> 2, 4, 4, 3, 3, 4, 3, 3, 3, 3, 1, 3, 2, 3, 2, 3, 2, 4, 2, 4, 4~
$ id01     <dbl> 3, 3, 3, 1, 2, 3, 3, 1, 2, 3, 2, 4, 1, 4, 2, 2, 3, 3, 3, 3, 3~
$ im01     <dbl> 2, NA, NA, 2, 2, 1, 2, 2, 2, 2, 1, NA, 2, 1, 2, 2, NA, 2, 1, ~
$ im17     <dbl> 2, 4, 3, 2, 2, 3, 2, 3, 2, 2, 2, NA, 2, 4, 1, 4, 2, 3, 2, 3, ~
$ im18     <dbl> 1, 4, 4, 3, 2, 4, 2, 2, 2, 3, 2, NA, 3, 3, 1, 4, 3, 3, 1, 3, ~
```

```
$ im19     <dbl> 4, 1, 2, 2, 3, 3, 3, 3, 4, 3, 2, NA, 3, 2, 4, 1, 2, 3, 2, 2, ~
$ im20     <dbl> 3, 3, 1, 3, 3, 2, 3, 3, 3, 3, 2, NA, 3, 2, 4, 3, 2, 2, 2, 3, ~
$ im21     <dbl> 4, 3, 1, 3, 3, 2, 3, 4, 4, 4, 3, NA, 3, 2, 4, 2, 3, 3, 3, 3, ~
$ iw04     <dbl> 1, 4, 2, 2, 2, 2, 2, 2, 2, 1, 2, 1, 2, 3, 1, 2, 1, 2, 1, 1, 2~
$ pd11     <dbl> 2, 1, 2, 1, 1, 1, 2, 2, 2, 1, 1, 2, 2, 1, 2, 2, 2, 1, 2, 1, 1~
$ pi07     <dbl> 2, NA, NA, 2, 1, 1, 2, 1, 2, 1, NA, NA, 1, 1, 2, 1, NA, NA, 2~
$ pi01     <dbl> 1, 1, 2, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1~
$ pi02     <dbl> 3, 2, NA, 3, 3, NA, 2, 2, 2, 2, NA, 2, 2, 2, 3, 1, 3, 2, 3, N~
$ lp03     <dbl> 1, 2, 2, 1, 1, 1, 2, 1, 1, 1, NA, 2, 2, 2, 1, 2, 1, 2, 1, 2, ~
$ lp04     <dbl> 2, 2, 1, NA, NA, 2, 2, 2, 1, 2, 1, 2, 2, 2, 1, 2, 1, 1, 2, 2,~
$ lp05     <dbl> 1, 2, 1, 1, 1, 2, 1, 1, 1, 1, NA, 2, 1, 2, 1, 1, 1, 2, 1, 2, ~
$ lp06     <dbl> 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 1, 1, 1, 2, 1, 2, 1~
$ hs01     <dbl> 4, 3, 2, 3, 3, 2, 1, 2, 4, 3, 2, 4, 3, 2, 3, 4, 4, 2, 2, 1, 3~
$ hs04     <dbl> 3, NA, NA, 4, 3, 2, 1, 3, 4, 2, 4, NA, 2, 2, 3, 2, NA, 2, 2, ~
$ hs05     <dbl> 2, NA, NA, 4, 3, 3, 2, 2, 3, 2, 5, NA, 4, 3, 3, 3, NA, 3, 3, ~
$ hs06     <dbl> 3, NA, NA, 5, 2, 3, 3, 4, 3, 4, 2, NA, 3, 3, 4, 3, NA, 2, 3, ~
$ hs07     <dbl> 3, NA, NA, 3, 3, 3, 4, 4, 4, 4, 2, NA, 2, 3, 3, 4, NA, 3, 4, ~
$ hs09     <dbl> 5, NA, NA, 5, 4, 3, 3, 4, 4, 5, 2, NA, 4, 2, 3, 4, NA, 4, 2, ~
$ land     <dbl> 80, 50, 10, 160, 50, 90, 50, 70, 160, 60, 90, 120, 140, 60, 9~
$ bik      <dbl> 3, 3, 4, 2, 7, 8, 10, 4, 3, 4, 9, 10, NA, 3, 10, 8, 1, 10, 4,~
$ gkpol    <dbl> 3, 3, 3, 2, 3, 6, 7, 1, 3, 3, 2, 4, NA, 3, 7, 6, 1, 7, 3, 7, ~
```

```
glimpse(df_spss)
```

```
Rows: 5,342
Columns: 65
$ eastwest <dbl+lbl> 1, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 2, 2, 1, 1, 1, 1, 1, 1, ~
$ german   <dbl+lbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 3, 1, 1, 3, 3, 1, 1, 1, 1, ~
$ sex      <dbl+lbl> 2, 1, 2, 1, 2, 1, 2, 2, 1, 2, 1, 1, 2, 1, 1, 2, 1, 1, 1, ~
$ age      <dbl+lbl> 54, 53, 89, 79, 62, 23, 31, 57, 68, 51, 57, 85, 55, 26, 3~
$ agec     <dbl+lbl> 3, 3, 5, 5, 4, 1, 2, 3, 4, 3, 3, 5, 3, 1, 2, 3, 3, 3, 3, ~
$ dg10     <dbl+lbl>  1,  8,  7, 17,  8,  2,  8, 12, 17,  7, 95, 17, 15, 95, 9~
$ dg03     <dbl+lbl>  4,  4,  4,  1,  4,  4,  4,  2,  1,  4, NA,  1,  1, NA, N~
$ educ     <dbl+lbl>  5,  5,  4,  4,  2,  7,  5,  4,  3,  3, NA,  5,  3,  2, N~
$ isced97  <dbl+lbl>  5,  5,  4,  5,  3, NA,  6,  5,  5,  3,  5,  5,  5,  5,  ~
$ iscd11   <dbl+lbl>  5,  6,  4,  5,  3, NA,  8,  5,  7,  3,  5,  7,  5,  5,  ~
$ work     <dbl+lbl> 1, 1, 4, 4, 4, 4, 2, 1, 4, 2, 4, 4, 2, 1, 1, 2, 1, 2, 1, ~
$ isco08   <dbl+lbl> 5244, 2421,   NA,   NA,   NA,   NA, 2310, 4110,   NA, 322~
$ siops08  <dbl+lbl> 26.00, 55.80,    NA,    NA,    NA,    NA, 78.16, 42.09,  ~
$ isei08   <dbl+lbl> 38.88, 70.09,    NA,    NA,    NA,    NA, 85.41, 43.33,  ~
$ dw15     <dbl+lbl> 35.0, 62.0,   NA,   NA,   NA,   NA, 32.0, 39.5,   NA, 30.~
```

```
$ dw16     <dbl+lbl>  1, NA, NA, NA, NA, NA,  2,  1, NA,  1, NA, NA,  1, NA,  ~
$ dw19c    <dbl+lbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
$ dw03     <dbl+lbl> NA, NA,  2,  2,  4,  1, NA, NA,  2, NA,  3,  2, NA, NA, N~
$ mstat    <dbl+lbl> 5, 5, 3, 1, 1, 5, 5, 1, 1, 5, 3, 1, 1, 5, 4, 1, 4, 1, 5, ~
$ dp01     <dbl+lbl>  1,  2,  2, NA, NA,  1,  1, NA, NA,  1,  2, NA, NA,  2,  ~
$ di01a    <dbl+lbl>   NA,   NA,   NA,   NA,   NA,   NA, 1900,   NA, 1300,   N~
$ di02a    <dbl+lbl> 10, 19, NA, 12, NA, NA, NA, 15, NA, 13, NA, 16, 13, 14, 1~
$ incc     <dbl+lbl> 10, 19, NA, 12, NA, NA, 14, 15, 11, 13,  3, 16, 13, 14, 1~
$ di01b    <dbl+lbl>   NA,   NA,   NA,   NA,   NA,   NA, 5000,   NA, 1900,   N~
$ di02b    <dbl+lbl> NA, NA, NA, 15, 19, 12, NA, 20, NA, NA,  3, 19, 19, NA, N~
$ di05     <dbl+lbl>   NA,   NA,   NA,   NA,   NA,   NA, 5000,   NA, 1900,   N~
$ di06     <dbl+lbl> 10, 19, NA, 15, 19, 12, NA, 20, NA, NA,  3, 19, 19, 14, 1~
$ hhincc   <dbl+lbl> 10, 19, NA, 15, 19, 12, 23, 20, 14, NA,  3, 19, 19, 14, 1~
$ dh01     <dbl+lbl> 2, 2, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 1, 1, 1, 2, ~
$ dh11     <dbl+lbl> NA, NA, NA,  1,  2,  1,  2,  1,  1,  4,  3,  1,  1, NA, N~
$ aq01     <dbl+lbl>  4,  7,  8,  7,  7,  4,  4,  7,  5,  7,  6, NA,  7,  4,  ~
$ gs01     <dbl+lbl> 4, 3, 3, 3, 4, 1, 1, 4, 3, 4, 4, 3, 4, 4, 1, 1, 4, 1, 3, ~
$ gd01     <dbl+lbl>   NA, 9000, 2011,   NA,   NA,   NA, 2012,   NA, 1975,   N~
$ gd02     <dbl+lbl> NA, 53, 10, NA, NA, NA,  9, NA, 46, NA, NA, 59, NA, NA, N~
$ dg13     <dbl+lbl> NA, NA,  5, NA, NA, NA,  6, NA,  1, NA, NA,  5, NA, NA, N~
$ dg08     <dbl+lbl> NA,  1,  2, NA, NA, NA,  1, NA, NA, NA, NA, NA, NA, NA, N~
$ dg09     <dbl+lbl> NA, NA, NA, NA, NA, NA, NA, NA,  2, NA, NA,  1, NA, NA, N~
$ dg11     <dbl+lbl> NA,  1,  2, NA, NA, NA,  1, NA,  2, NA, NA,  1, NA, NA, N~
$ ls01     <dbl+lbl>  8, 10,  9,  9,  8,  8,  7,  5,  5,  9,  6,  7,  7,  8,  ~
$ id02     <dbl+lbl> 2, 4, 4, 3, 3, 4, 3, 3, 3, 3, 1, 3, 2, 3, 2, 3, 2, 4, 2, ~
$ id01     <dbl+lbl> 3, 3, 3, 1, 2, 3, 3, 1, 2, 3, 2, 4, 1, 4, 2, 2, 3, 3, 3, ~
$ im01     <dbl+lbl>  2, NA, NA,  2,  2,  1,  2,  2,  2,  2,  1, NA,  2,  1,  ~
$ im17     <dbl+lbl>  2,  4,  3,  2,  2,  3,  2,  3,  2,  2,  2, NA,  2,  4,  ~
$ im18     <dbl+lbl>  1,  4,  4,  3,  2,  4,  2,  2,  2,  3,  2, NA,  3,  3,  ~
$ im19     <dbl+lbl>  4,  1,  2,  2,  3,  3,  3,  3,  4,  3,  2, NA,  3,  2,  ~
$ im20     <dbl+lbl>  3,  3,  1,  3,  3,  2,  3,  3,  3,  3,  2, NA,  3,  2,  ~
$ im21     <dbl+lbl>  4,  3,  1,  3,  3,  2,  3,  4,  4,  4,  3, NA,  3,  2,  ~
$ iw04     <dbl+lbl> 1, 4, 2, 2, 2, 2, 2, 2, 2, 1, 2, 1, 2, 3, 1, 2, 1, 2, 1, ~
$ pd11     <dbl+lbl> 2, 1, 2, 1, 1, 1, 2, 2, 2, 1, 1, 2, 2, 1, 2, 2, 2, 1, 2, ~
$ pi07     <dbl+lbl>  2, NA, NA,  2,  1,  1,  2,  1,  2,  1, NA, NA,  1,  1,  ~
$ pi01     <dbl+lbl> 1, 1, 2, 1, 1, 2, 1, 1, 1, 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, ~
$ pi02     <dbl+lbl>  3,  2, NA,  3,  3, NA,  2,  2,  2,  2, NA,  2,  2,  2,  ~
$ lp03     <dbl+lbl>  1,  2,  2,  1,  1,  1,  2,  1,  1,  1, NA,  2,  2,  2,  ~
$ lp04     <dbl+lbl>  2,  2,  1, NA, NA,  2,  2,  2,  1,  2,  1,  2,  2,  2,  ~
$ lp05     <dbl+lbl>  1,  2,  1,  1,  1,  2,  1,  1,  1,  1, NA,  2,  1,  2,  ~
$ lp06     <dbl+lbl> 1, 2, 1, 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 1, 1, 1, 2, 1, ~
```

```
$ hs01     <dbl+lbl> 4, 3, 2, 3, 3, 2, 1, 2, 4, 3, 2, 4, 3, 2, 3, 4, 4, 2, 2, ~
$ hs04     <dbl+lbl>  3, NA, NA,  4,  3,  2,  1,  3,  4,  2,  4, NA,  2,  2,  ~
$ hs05     <dbl+lbl>  2, NA, NA,  4,  3,  3,  2,  2,  3,  2,  5, NA,  4,  3,  ~
$ hs06     <dbl+lbl>  3, NA, NA,  5,  2,  3,  3,  4,  3,  4,  2, NA,  3,  3,  ~
$ hs07     <dbl+lbl>  3, NA, NA,  3,  3,  3,  4,  4,  4,  4,  2, NA,  2,  3,  ~
$ hs09     <dbl+lbl>  5, NA, NA,  5,  4,  3,  3,  4,  4,  5,  2, NA,  4,  2,  ~
$ land     <dbl+lbl>  80,  50,  10, 160,  50,  90,  50,  70, 160,  60,  90, 12~
$ bik      <dbl+lbl>  3,  3,  4,  2,  7,  8, 10,  4,  3,  4,  9, 10, NA,  3, 1~
$ gkpol    <dbl+lbl>  3,  3,  3,  2,  3,  6,  7,  1,  3,  3,  2,  4, NA,  3,  ~
```

---

### Exkurs: Datensatzstruktur

Bevor wir mit der Datenaufbereitung weitermachen, schauen wir uns an, **wie ein Datensatz in R grundsätzlich aufgebaut ist** und wie wir auf einzelne Variablen zugreifen können.

Ein Datensatz (Data Frame) ist in R eine **Sammlung von Variablen**,
die jeweils als Spalten organisiert sind.

**Objekte entfernen**

Wir können auch einzelne oder mehre Objekte wieder aus unserem Environment entfernen, dafür nutzen wir die Funktion `rm()`.

```
rm(x)

# Mehrere Variablen aufeinmal

rm(x,y,m,s)
```

```
Warning in rm(x, y, m, s): Objekt 'x' nicht gefunden
```

### Zugriff auf Variablen mit `$`

In Base R greifen wir auf einzelne Variablen eines Datensatzes
mit dem **Dollar-Zeichen `$`** zu.

Dafür schauen wir uns unser Environment mit unseren Datensätzen an.

---

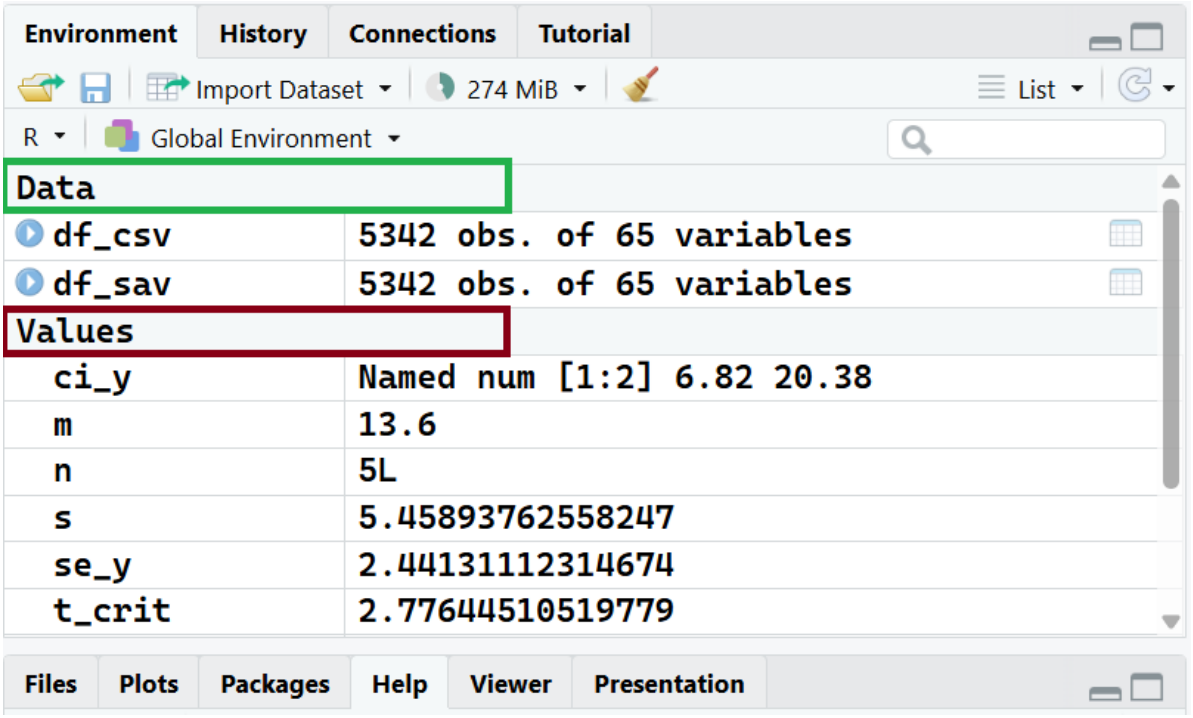


Wir sehen zunächst, dass **RStudio** direkt zwischen Values (einzelne Werte) und Data (Datensätzen, Tabellen und anderen Objekten) unterscheden kann.

---

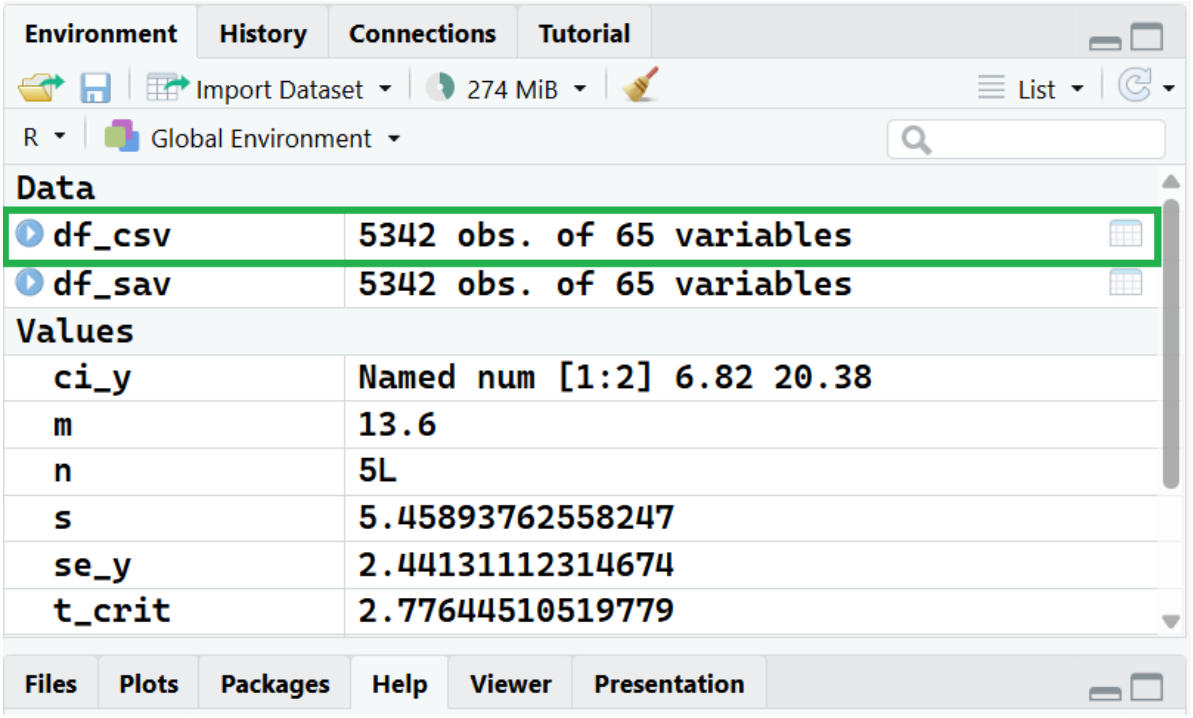


Wir schauen uns jetzt mal unseren Datensatzobjekt genauer an. Klicke einfach auf den Datensatz `df_csv` und neben deinem Script sollte sich nun der Datensatz öffnen.

---

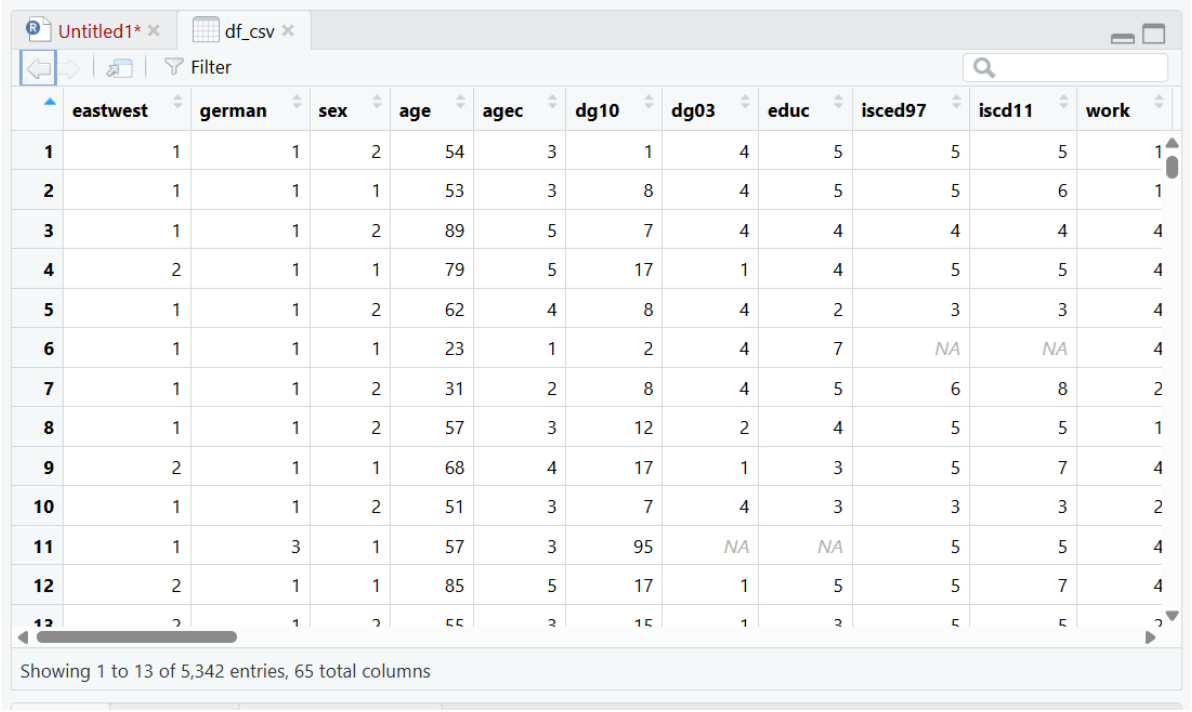


| | eastwest | german | sex | age | agec | dg10 | dg03 | educ | isced97 | iscd11 | work |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | 1 | 2 | 54 | 3 | 1 | 4 | 5 | 5 | 5 | 1 |
| 2 | 1 | 1 | 1 | 53 | 3 | 8 | 4 | 5 | 5 | 6 | 1 |
| 3 | 1 | 1 | 2 | 89 | 5 | 7 | 4 | 4 | 4 | 4 | 4 |
| 4 | 2 | 1 | 1 | 79 | 5 | 17 | 1 | 4 | 5 | 5 | 4 |
| 5 | 1 | 1 | 2 | 62 | 4 | 8 | 4 | 2 | 3 | 3 | 4 |
| 6 | 1 | 1 | 1 | 23 | 1 | 2 | 4 | 7 | NA | NA | 4 |
| 7 | 1 | 1 | 2 | 31 | 2 | 8 | 4 | 5 | 6 | 8 | 2 |
| 8 | 1 | 1 | 2 | 57 | 3 | 12 | 2 | 4 | 5 | 5 | 1 |
| 9 | 2 | 1 | 1 | 68 | 4 | 17 | 1 | 3 | 5 | 7 | 4 |
| 10 | 1 | 1 | 2 | 51 | 3 | 7 | 4 | 3 | 3 | 3 | 2 |
| 11 | 1 | 3 | 1 | 57 | 3 | 95 | NA | NA | 5 | 5 | 4 |
| 12 | 2 | 1 | 1 | 85 | 5 | 17 | 1 | 5 | 5 | 7 | 4 |
| 13 | 2 | 1 | 2 | 55 | 3 | 15 | 1 | 3 | 5 | 5 | 2 |

Showing 1 to 13 of 5,342 entries, 65 total columns

Mit `view(df_csv)` würden wir auf das selbe Ergebnis kommen. Jetzt kannst du dir deinen Datensatz im Detail anschauen.

---

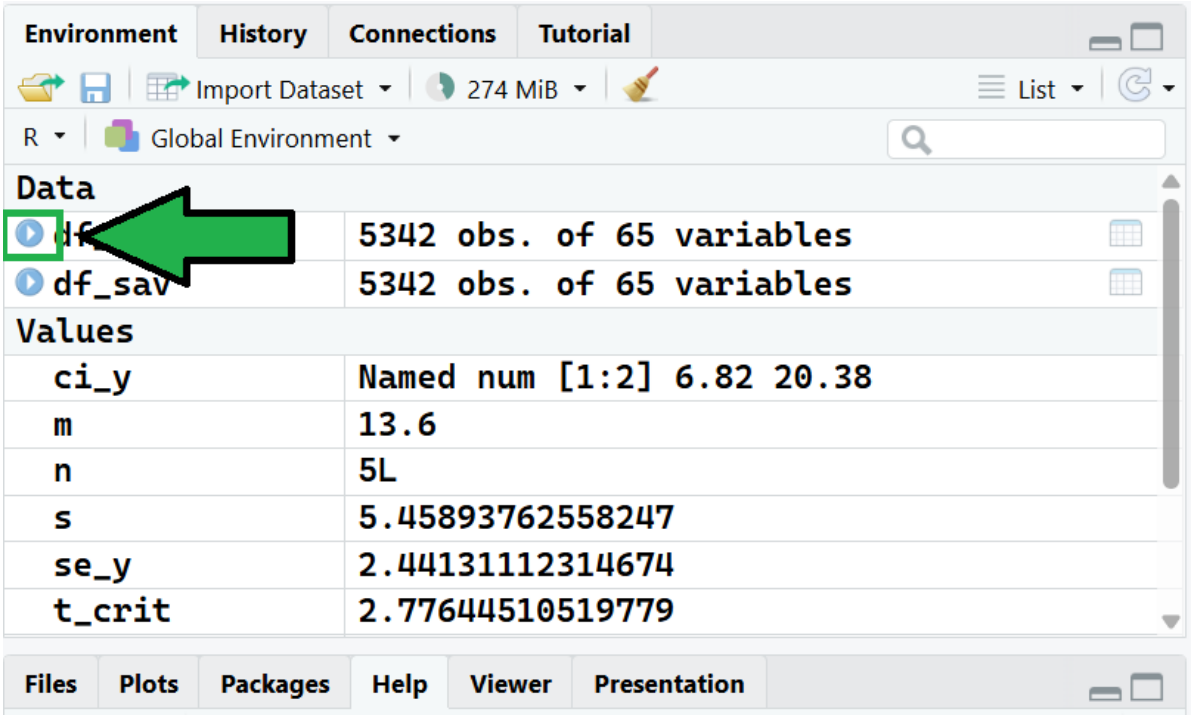


Zurück zum Environment! Mit einem Klick auf den blauen Pfeil neben dem Objektnamen, öffnest du ein Dropdown mit mehr Informationen zu diesem Objekt → Struktur und Inhalte des Objekts!

---

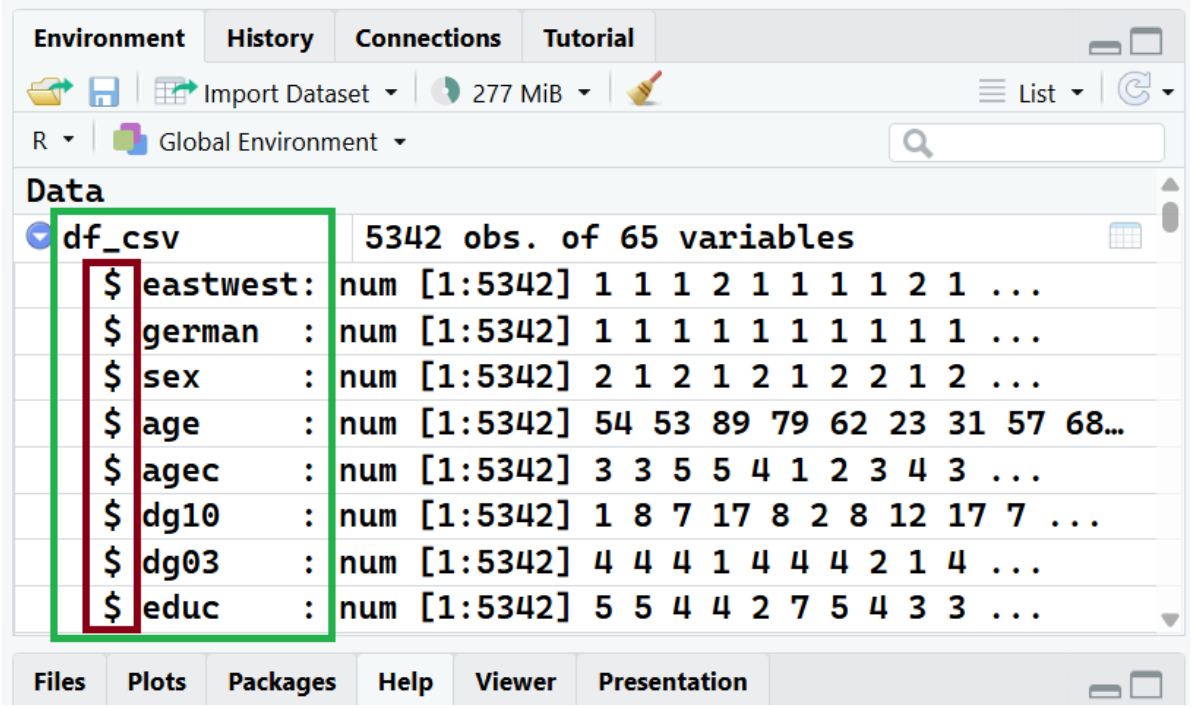


Was wir nun erkennen ist ein logischer Aufbau des Objekts. Wir sehen den Objektnamen als übergeordnete Struktur und die Inhalte des Objekts, in diesem Fall, die Variablen als untergeordnete Struktur. Getrennt werden diese zwei **"Ebenen"** durch das `$`.

---

Wie können wir nun explizit auf unsere Variable zugreifen? Wenn wir nun die Logik des Aufbaus anschauen, kommen wir zum Schluss:

1. Erst den Objektnamen eintippen → `df_csv`
2. Dann die untere Ebene "aufmachen" → `$`
3. Dann **Variablennamen** eintippen, die ich ansteuern möchte → `age`

```
df_csv$age
```

In eurem Output, sollten nun alle Altersangaben der Teilnehmden Personen dieser Studie als Vektor angezeigt werden.

**Übung 5** – Anwendung

Deine Aufgabe ist es nun, das Durchschnittsalter (Mean) und die Standardabweichung des Durschnittsalters (SD) zu berechnen.

**Lösung - Übung 5**

## Alternative 1

```
mean(df_csv$age, na.rm=TRUE)
```

```
[1] 53.27089
```

```
sd(df_csv$age, na.rm=TRUE)
```

```
[1] 17.64202
```

## Alternative 2

```
library(psych)

describe(df_csv$age)
```

```
   vars    n  mean    sd median trimmed   mad min max range skew kurtosis   se
X1    1 5301 53.27 17.64     55   53.44 19.27  18  96    78 -0.1    -
0.86 0.24
```

---

### Einführung dplyr

`dplyr` ist Teil des **tidyverse** und bietet Funktionen,
mit denen sich Datensätze **lesbar, konsistent und effizient** bearbeiten lassen.

Der Fokus liegt dabei auf: - klarer, gut nachvollziehbarer Syntax
- schrittweisem Arbeiten
- einer einheitlichen „Grammatik“ für Datenmanipulation

**!** Wichtigsten Funktionen:

- `select()` – Variablen auswählen
- `filter()` – Fälle auswählen

- `mutate()` – neue Variablen erstellen
- `arrange()` – sortieren
- `rename()` – Variablen umbenennen

Bevor wir mehrere Schritte kombinieren,
schauen wir uns ein **einzelnes, einfaches Beispiel** an.

```
select(df_csv, age, sex)
```

```
# A tibble: 5,342 x 2
     age   sex
   <dbl> <dbl>
 1    54     2
 2    53     1
 3    89     2
 4    79     1
 5    62     2
 6    23     1
 7    31     2
 8    57     2
 9    68     1
10    51     2
# i 5,332 more rows
```

Der `select()` wählt Variablen aus und macht aus den einen neuen Datensatz (`tibble` fungiert genauso wie ein `Data Frame`).

**Achtung**

Ohne die **korrekte Zuweisung**, wird **kein neues Objekt** erstellt!

```
df_2var <- select(df_csv, age, sex)

df_2var
```

```
# A tibble: 5,342 x 2
     age   sex
   <dbl> <dbl>
 1    54     2
 2    53     1
```

```
 3    89     2
 4    79     1
 5    62     2
 6    23     1
 7    31     2
 8    57     2
 9    68     1
10    51     2
# i 5,332 more rows
```

Die Logik ist relativ klar! 1. Nenne das Objekt (Datensatz) 2. Reihe die Variablen aneinander, die ausgewählt werden sollen

Die Datenaufbereitung besteht meistens aus **mehreren Schritten:** - Variablen auswählen - Fälle filtern - neue Variablen erstellen (Summenwerte) - Variablen umbenennen

Wir wählen nun wieder unsere Variablen aus und filtern diese aber nun. Wir wollen nun alle Personen über 30 Jahre behalten.

## Alternative 1

```
df_2var <- select(df_csv, age, sex)

df_2var
```

```
# A tibble: 5,342 x 2
     age   sex
   <dbl> <dbl>
 1    54     2
 2    53     1
 3    89     2
 4    79     1
 5    62     2
 6    23     1
 7    31     2
 8    57     2
 9    68     1
10    51     2
# i 5,332 more rows
```

## Alternative 2

```
#| echo: true

df_2var <- filter(select(df_csv, age, sex), age >= 30)

df_2var
```

```
# A tibble: 4,683 x 2
     age   sex
   <dbl> <dbl>
 1    54     2
 2    53     1
 3    89     2
 4    79     1
 5    62     2
 6    31     2
 7    57     2
 8    68     1
 9    51     2
10    57     1
# i 4,673 more rows
```

Die Logik des Befehls **"Alternative 2"** ist wie folgt aufgebaut: - `filter()` den neuen Datensatz, welcher durch `select()` erstellt wurde **oder** - Wähle erst die Variablen aus und filter anschließend (**Alternative 1**)

**Alternative 2** wirkt auf den ersten Blick effizienter, jedoch liest es sich auch sehr kompliziert. Gerade wenn man mehrere Schritte durchführen möchte.

Auch dafür gibt es in **Rstudio** eine effiziente Lösung → **Pipes**

### Pipes

Pipes in R sind ein Operator (z.B. `%>%` oder `|>`), mit dem das Ergebnis **eines Schritts direkt** an den **nächsten Befehl „weitergereicht"** wird, ohne Zwischenergebnisse extra zu speichern. Dadurch lassen sich **Datenbearbeitungsschritte** wie in einer Kette von links nach rechts lesen, was den **Code meist kürzer und besser lesbar** macht, besonders im Tidyverse-Kontext.

Man kann sich Pipes vorstellen wie die Röhren (Pipes) aus Super Mario:

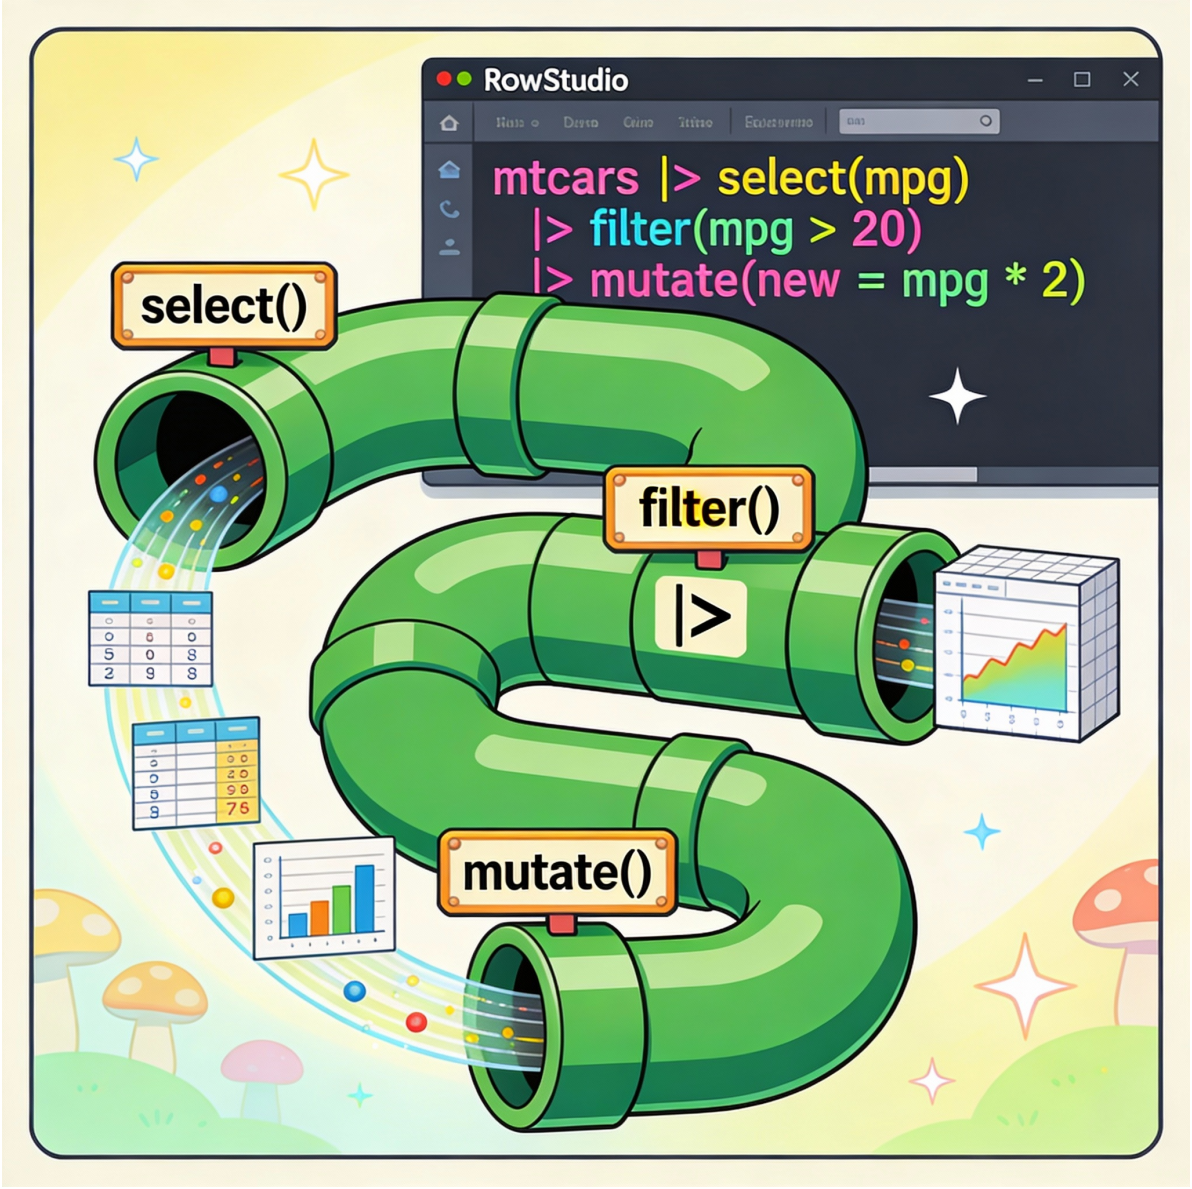


```
#| echo: true

df_2var <- df_csv |>
select(age, sex) |>
filter(age >= 30)

df_2var
```

```
# A tibble: 4,683 x 2
```

```
     age   sex
   <dbl> <dbl>
 1    54     2
 2    53     1
 3    89     2
 4    79     1
 5    62     2
 6    31     2
 7    57     2
 8    68     1
 9    51     2
10    57     1
# i 4,673 more rows
```

Wie wir sehen, haben wir eine klare Struktur und wir müssen den Befehlen innerhalb unserer eigenen **Pipes** nicht dauernd "erklären", welchen Datensatz wir heranziehen!

**Übung 6** – Datenaufbereitung!

1. Erstelle zunächst eine neue Variable `soz.u`, diese Besteht aus den Variablen `im17` bis `im21` –> bilde dafür einen Summenwert
2. Erstelle einen neuen Datensatz `df_analyse` mit folgenden Variablen `Alter, Geschlecht, Bildung, Berufstätigkeit und Sozialeungleichheit`
3. Filtere nur die Personen, die `weiblich`angegeben haben in einen neuen Datensatz `df_analyse_w`

**TIPP**

- Nutze das **Codebook!**
- **Erinnere** dich an die wichtigsten Funktionen von `dplyr`
- Verwende **Pipes**, wenn du diese brauchst

Das wichtigste: **LEARNING BY DOING!**

**Lösung - Übung 6**

## Alternative 1

```r
# Aufgabe 1

df_csv <- df_csv |>
mutate(soz.u = im17+im18+im19+im20+im21)

head(df_csv$soz.u, 10)
```

```
 [1] 14 15 11 13 13 14 13 15 15 15
```

```r
# Aufgabe 2

df_analyse <- df_csv |>
select(age, sex, educ, work, soz.u)

head(df_analyse, 10)
```

```
# A tibble: 10 x 5
     age   sex  educ  work soz.u
   <dbl> <dbl> <dbl> <dbl> <dbl>
 1    54     2     5     1    14
 2    53     1     5     1    15
 3    89     2     4     4    11
 4    79     1     4     4    13
 5    62     2     2     4    13
 6    23     1     7     4    14
 7    31     2     5     2    13
 8    57     2     4     1    15
 9    68     1     3     4    15
10    51     2     3     2    15
```

```r
# Aufgabe 3

df_analyse_w <- df_analyse |>
filter(sex == 2)

head(df_analyse_w, 10)
```

```
# A tibble: 10 x 5
     age   sex  educ  work soz.u
   <dbl> <dbl> <dbl> <dbl> <dbl>
 1    54     2     5     1    14
```

```
 2    89     2     4     4    11
 3    62     2     2     4    13
 4    31     2     5     2    13
 5    57     2     4     1    15
 6    51     2     3     2    15
 7    55     2     3     2    14
 8    58     2     3     2    14
 9    83     2     3     4    13
10    48     2    NA     2    17
```

## Alternative 2

```
df_analyse <- df_csv |>
  mutate(soz.u = im17 + im18 + im19 + im20 + im21) |>
  select(age, sex, educ, work, soz.u)

head(df_analyse, 10)
```

```
# A tibble: 10 x 5
     age   sex  educ  work soz.u
   <dbl> <dbl> <dbl> <dbl> <dbl>
 1    54     2     5     1    14
 2    53     1     5     1    15
 3    89     2     4     4    11
 4    79     1     4     4    13
 5    62     2     2     4    13
 6    23     1     7     4    14
 7    31     2     5     2    13
 8    57     2     4     1    15
 9    68     1     3     4    15
10    51     2     3     2    15
```

```
df_analyse_w <- df_analyse |>
    filter(sex == 2)

head(df_analyse_w, 10)
```

```
# A tibble: 10 x 5
     age   sex  educ  work soz.u
   <dbl> <dbl> <dbl> <dbl> <dbl>
 1    54     2     5     1    14
```

```
 2    89     2     4     4    11
 3    62     2     2     4    13
 4    31     2     5     2    13
 5    57     2     4     1    15
 6    51     2     3     2    15
 7    55     2     3     2    14
 8    58     2     3     2    14
 9    83     2     3     4    13
10    48     2    NA     2    17
```

## Abschluss Tag 1

Heute hast du die Grundlagen gelegt, um sicher mit RStudio zu arbeiten:

- RStudio-Oberfläche und Projekte kennengelernt
- erste Objekte und Vektoren erstellt
- Datentypen und Datenstrukturen verstanden
- einen Datensatz importiert und plausibilisiert
- erste Schritte der Datenaufbereitung mit **dplyr** und **Pipes** gemacht

Ausblick auf Tag 2

Morgen bauen wir auf diesen Grundlagen auf und gehen einen Schritt weiter in Richtung „echter Analyse-Workflow“:

- **Recap** (kurzer Rückblick & Fragen)
- **Fehlende Werte** (NA erkennen, zählen, behandeln)
- **Umkodieren** (neue Kategorien, Skalen, Re-Codes)
- **Joins** (Datensätze zusammenführen)
- **Reproduzierbare Workflows** (Ordnerstruktur, Skripte, Output)
- **Mini-Projekt** (alles zusammen anwenden)

**Speichere dein Projekt**, damit du morgen direkt weiterarbeiten kannst.

---

Weiter zu Tag 2